ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN - TIN HỌC

BÁO CÁO SEMINAR

HỌC KỲ I, 2025 - 2026

ĐỀ TÀI

Enhancing Paper Submission Recommendation Using Large Language Models

Giảng viên hướng dẫn: ThS. Huỳnh Thanh Sơn

Sinh viên thực hiện:

22110033 - Lê Thị Hồng Đang 22110008 - Trần Duy An

Thành phố Hồ Chí Minh, 2026

Mục lục

1 Tổng quan **4**
1.1 Lý do chọn đề tài . . . 4
1.2 Các công trình nghiên cứu khoa học có liên quan . . . 5
1.3 Xây dựng bài toán nghiên cứu . . . 5
1.4 Sơ lược về các cách tiếp cận trong đề tài nghiên cứu . . . 7

2 Cơ sở lý thuyết **8**
2.1 Biểu diễn văn bản trong xử lý ngôn ngữ tự nhiên . . . 8
2.1.1 Biểu diễn dựa trên từ (Word-level Representation) . . . 8
2.1.2 Biểu diễn dựa trên thống kê . . . 9
2.1.3 Biểu diễn ngữ cảnh (Contextualized Representation) . . . 9
2.1.4 So sánh biểu diễn tĩnh và biểu diễn ngữ cảnh . . . 9
2.2 Kiến trúc Transformer . . . 10
2.2.1 Multi-head Attention . . . 10
2.2.2 Cơ chế Self-Attention . . . 10
2.2.3 Encoder Transformer . . . 11
2.3 Học tương phản (Contrastive Learning) . . . 11
2.3.1 Contrastive Learning trong bài toán matching . . . 11
2.3.2 Hàm mất mát tương phản . . . 12
2.3.3 Vai trò của tham số nhiệt độ trong học tương phản . . . 13
2.4 Cơ chế Cross-Attention . . . 13
2.4.1 So sánh Self-Attention và Cross-Attention . . . 14
2.4.2 Định nghĩa Cross-Attention . . . 14
2.4.3 Hàm score trong Cross-Attention . . . 14
2.5 Tổng kết chương . . . 15

3 Phương pháp thí nghiệm **16**
3.1 Tiền xử lý dữ liệu . . . 16
3.1.1 Cấu trúc dữ liệu đầu vào . . . 16
3.1.2 Quy trình tiền xử lý văn bản . . . 16
3.1.3 Tổ hợp đặc trưng đầu vào . . . 17
3.1.4 Xây dựng biểu diễn đầu vào cho các phương pháp . . . 17
3.2 Tổng quan pipeline hệ thống . . . 18
3.3 Dữ liệu và tổ hợp đặc trưng . . . 19
3.3.1 Nguồn dữ liệu và cấu trúc mẫu . . . 19
3.3.2 Tổ hợp đặc trưng . . . 19
3.4 Approach A – Phương pháp cơ sở (Baseline) . . . 20
3.4.1 Pipeline xử lý . . . 20
3.4.2 Thuật toán huấn luyện . . . 20
3.4.3 Nhận xét . . . 21
3.5 Approach B – Transformer-based Pipeline . . . 21
3.5.1 Pipeline xử lý . . . 21
3.5.2 Chiến lược pooling . . . 21
3.6 Approach C – Embedding-based Contrastive Learning (SimCPSR)[13] . . . 21
3.6.1 Huấn luyện hai giai đoạn . . . 21
3.6.2 Thuật toán huấn luyện . . . 23
3.6.3 Hạn chế . . . 23

3.7 Phân tích pipeline và vai trò của từng phương pháp . . . 23
3.7.1 Vai trò của Approach A trong pipeline . . . 23
3.7.2 Vai trò của Approach B trong pipeline . . . 24
3.7.3 Vai trò của Approach C trong pipeline . . . 24
3.7.4 Tổng hợp và định hướng phát triển . . . 24
3.8 Approach D – Phương pháp đề xuất dựa trên Cross-Attention . . . 25
3.8.1 Động cơ và định hướng tiếp cận . . . 25
3.8.2 Biểu diễn đầu vào và kiến trúc tổng thể . . . 25
3.8.3 Cơ chế Cross-Attention trong pipeline . . . 26
3.8.4 Chiến lược pooling và biểu diễn tương tác . . . 27
3.8.5 Thuật toán huấn luyện . . . 28
3.8.6 Thuật toán suy luận và gợi ý Top-K . . . 28
3.8.7 Phân tích độ phức tạp tính toán . . . 28
3.8.8 Thảo luận thiết kế và so sánh với Approach C . . . 28
3.8.9 Tổng kết Approach D . . . 29
3.9 Cấu hình huấn luyện và thiết lập thực nghiệm . . . 29
3.10 Thảo luận lựa chọn thiết kế . . . 29
3.10.1 Vị trí tích hợp Cross-Attention . . . 30
3.10.2 So sánh Cross-Attention và so khớp embedding tĩnh . . . 30
3.10.3 Ảnh hưởng của chiến lược pooling . . . 30
3.10.4 Khả năng mở rộng và hạn chế . . . 30
3.10.5 Tổng kết thảo luận thiết kế . . . 30
3.11 Tổng kết chương . . . 31

4 Thực nghiệm và đánh giá **32**
4.1 Mô tả tập dữ liệu . . . 32
4.1.1 Nguồn dữ liệu . . . 32
4.1.2 Quy mô và cách chia dữ liệu . . . 32
4.1.3 Cấu trúc dữ liệu bài báo . . . 32
4.1.4 Cấu trúc dữ liệu hội nghị và tạp chí . . . 33
4.2 Các kết quả thực nghiệm trước đó (từ simCPSR) . . . 34
4.2.1 Độ đo đánh giá . . . 34
4.2.2 Kết quả thực nghiệm . . . 34
4.3 Thiết lập thực nghiệm . . . 35
4.3.1 Phạm vi dữ liệu . . . 35
4.3.2 Độ đo đánh giá . . . 36
4.4 Kết quả thực nghiệm và phân tích . . . 37
4.4.1 Kết quả với M = 10 . . . 37
4.4.2 Kết quả với M = 20 . . . 38
4.4.3 Kết quả với M = 30 . . . 38
4.4.4 Kết quả với M = 50 . . . 38
4.4.5 Biểu đồ so sánh . . . 39
4.4.6 Tổng kết . . . 39

5 Kết luận và hướng phát triển **41**
5.1 Kết luận . . . 41
5.2 Hạn chế . . . 41
5.3 Hướng phát triển trong tương lai . . . 42

Danh sách hình vẽ

1 Minh họa biểu diễn embedding tĩnh ở mức từ và phép trung bình để tạo embedding cho câu (Nguồn: [29]). . . . 8
2 Minh họa ma trận self-attention thể hiện mức độ chú ý giữa các token trong cùng một câu. (Nguồn: [8]) . . . 11
3 Minh họa kiến trúc Sentence-BERT cho bài toán so khớp câu, trong đó hai câu được mã hóa độc lập bằng BERT, sau đó so sánh bằng độ đo cosine similarity trong khoảng $[-1, 1]$. (Nguồn: [11]) . . . 13
4 Minh họa cơ chế cross-attention giữa các token của bài báo (Paper) và các token mô tả hội nghị hoặc tạp chí (Journal). Mỗi ô biểu diễn mức độ chú ý của một token trong bài báo đối với một token trong phần Aims & Scope. . . . 14
5 Pipeline tổng thể của hệ thống gợi ý nộp bài . . . 19
6 Pipeline của Approach A (FastText-based baseline) . . . 20
7 Pipeline của Approach B dựa trên Transformer . . . 21
8 Pipeline hai giai đoạn của phương pháp SimCPSR (Approach C). Giai đoạn đầu áp dụng contrastive learning trên biểu diễn bài báo (TAK), trong khi thông tin Aims & Scope chỉ được sử dụng ở giai đoạn khớp sau thông qua độ đo cosine. . 22
9 Kiến trúc tổng thể của phương pháp đề xuất dựa trên Cross-Attention (Approach D) . . . 26
10 Chi tiết khối Cross-Attention trong phương pháp đề xuất (Approach D) . . . 26
11 Pipeline suy luận của phương pháp đề xuất dựa trên Cross-Attention (Approach D) . . . 27
12 So sánh Hit@K giữa Approach C (TAKS) và Approach D (TAKS+D) theo các giá trị M khác nhau . . . 39

Danh sách bảng

1 Ví dụ cho quá trình tiền xử lý dữ liệu . . . 17
2 Một số ví dụ về Title, Abstract và Keywords trong tập dữ liệu đã được tiền xử lý 33
3 Một vài ví dụ về Aims and Scope thuộc các tạp chí có trong tập dữ liệu . . . 33
4 Accuracy@K của các tập đặc trưng trong các cách tiếp cận Approach A, Approach B và Approach C từ simCPSR . . . 34
5 So sánh Approach C và Approach D với $M = 10$ . . . 37
6 So sánh Approach C và Approach D với $M = 20$ . . . 38
7 So sánh Approach C và Approach D với $M = 30$ . . . 38
8 So sánh Approach C và Approach D với $M = 50$ . . . 38

1 Tổng quan

1.1 Lý do chọn đề tài

Trong kỷ nguyên số hóa và sự bùng nổ của dữ liệu lớn, cộng đồng nghiên cứu khoa học đang chứng kiến sự gia tăng theo cấp số nhân về số lượng các công bố học thuật. Theo các thống kê từ những cơ sở dữ liệu học thuật uy tín như Scopus và Web of Science, mỗi năm có hàng triệu bài báo khoa học được xuất bản trên toàn cầu, trải rộng trên hàng chục nghìn tạp chí và hội nghị thuộc nhiều lĩnh vực khác nhau. Sự phát triển mạnh mẽ này, mặc dù phản ánh sự tiến bộ không ngừng của tri thức nhân loại, đồng thời cũng đặt ra một thách thức nghiêm trọng đối với các nhà nghiên cứu: tình trạng quá tải thông tin và khó khăn trong việc lựa chọn nơi công bố phù hợp cho các công trình khoa học [1].

Việc lựa chọn địa điểm công bố (venue) không chỉ mang tính hình thức, mà còn ảnh hưởng trực tiếp đến khả năng được chấp nhận, thời gian phản biện, cũng như mức độ lan tỏa và tác động học thuật của bài báo. Trên thực tế, một tỷ lệ đáng kể các bài báo bị từ chối không xuất phát từ chất lượng khoa học yếu kém, mà do sự không tương thích giữa nội dung nghiên cứu và phạm vi (aims and scope) của tạp chí hoặc hội nghị mục tiêu. Đối với các nhà nghiên cứu trẻ hoặc những công trình mang tính liên ngành, quá trình lựa chọn venue thường phụ thuộc vào kinh nghiệm cá nhân, sự tư vấn chủ quan hoặc danh sách tài liệu tham khảo hạn chế, dẫn đến quy trình thử–sai tốn kém thời gian và nguồn lực.

Trước bối cảnh đó, việc phát triển các hệ thống gợi ý nộp bài tự động (Paper Submission Recommendation Systems – PSRS) đã trở thành một hướng nghiên cứu quan trọng, giao thoa giữa lĩnh vực Hệ thống gợi ý (Recommender Systems) và Xử lý ngôn ngữ tự nhiên (Natural Language Processing – NLP). Các phương pháp truyền thống dựa trên mô hình không gian vector và thống kê từ khóa như TF-IDF [2] đã đạt được những kết quả bước đầu, nhưng vẫn tồn tại hạn chế lớn trong việc xử lý hiện tượng bất đồng bộ từ vựng và chưa nắm bắt được ngữ cảnh ngữ nghĩa sâu của văn bản khoa học.

Sự ra đời của các mô hình học sâu, đặc biệt là kiến trúc Transformer [8], đã mở ra một bước ngoặt quan trọng cho NLP hiện đại. Trong số đó, mô hình BERT (Bidirectional Encoder Representations from Transformers) [25], với khả năng mã hóa ngữ cảnh hai chiều, đã chứng minh hiệu quả vượt trội trong nhiều bài toán hiểu ngôn ngữ tự nhiên. BERT cho phép xây dựng các biểu diễn ngữ nghĩa giàu thông tin, khắc phục những hạn chế cố hữu của các phương pháp nhúng từ tĩnh như Word2Vec [4] hay FastText [5].

Xuất phát từ bối cảnh trên, cùng với định hướng từ giáo viên hướng dẫn, báo cáo này lựa chọn nghiên cứu đề tài *"Enhancing Paper Submission Recommendation Using Large Language Models"*. Nghiên cứu được xây dựng dựa trên bài báo SimCPSR [7], trong đó tác giả đề xuất một khung học tương phản (Contrastive Learning) kết hợp với DistilRoBERTa nhằm học không gian biểu diễn chung cho bài báo và venue. Trên cơ sở đó, báo cáo tập trung khai thác và mở rộng việc ứng dụng các mô hình ngôn ngữ dựa trên BERT nhằm nâng cao chất lượng khớp nối ngữ nghĩa giữa nội dung bài báo và địa điểm công bố, góp phần giải quyết bài toán lựa chọn venue trong xuất bản khoa học hiện đại.

1.2 Các công trình nghiên cứu khoa học có liên quan

Lịch sử phát triển của các hệ thống gợi ý nộp bài báo khoa học phản ánh sự tiến hóa của các phương pháp xử lý ngôn ngữ tự nhiên, có thể được phân chia thành ba giai đoạn chính: (i) các phương pháp lọc nội dung truyền thống, (ii) các phương pháp học máy với nhúng từ, và (iii) các mô hình học sâu dựa trên kiến trúc Transformer.

Trong giai đoạn đầu, các hệ thống chủ yếu dựa trên mô hình không gian vector và kỹ thuật TF-IDF để biểu diễn văn bản [2]. Mặc dù dễ triển khai và có tính diễn giải cao, các phương pháp này gặp khó khăn trong việc xử lý các hiện tượng đồng nghĩa, đa nghĩa và hoàn toàn bỏ qua ngữ cảnh câu.

Giai đoạn tiếp theo chứng kiến sự xuất hiện của các kỹ thuật nhúng từ như Word2Vec [4] và FastText [5]. Các mô hình này cho phép biểu diễn ngữ nghĩa liên tục và giảm thiểu vấn đề từ vựng hiếm, tuy nhiên vẫn mang tính tĩnh và không phản ánh được sự thay đổi ngữ nghĩa theo ngữ cảnh.

Gần đây, các mô hình dựa trên kiến trúc Transformer, đặc biệt là BERT [25], đã trở thành nền tảng cho nhiều hệ thống gợi ý học thuật tiên tiến. Bài báo SimCPSR [7] là một trong những nghiên cứu tiêu biểu, áp dụng học tương phản để tối ưu hóa không gian biểu diễn giữa bài báo và venue, tạo nền tảng lý thuyết và thực nghiệm quan trọng cho nghiên cứu được trình bày trong báo cáo này.

1.3 Xây dựng bài toán nghiên cứu

Bài toán gợi ý nộp bài báo khoa học (Paper Submission Recommendation) được đặt ra nhằm hỗ trợ tác giả lựa chọn hội nghị hoặc tạp chí phù hợp nhất với nội dung học thuật của bài báo. Cụ thể, với một bài báo khoa học chưa được nộp, hệ thống cần đưa ra danh sách Top-K hội nghị hoặc tạp chí có mức độ phù hợp cao nhất dựa trên nội dung văn bản của bài báo và phạm vi nghiên cứu của từng địa điểm nộp bài.

Trong báo cáo này, mỗi bài báo được biểu diễn thông qua các trường văn bản học thuật gồm *Title*, *Abstract* và *Keywords*, trong khi mỗi hội nghị hoặc tạp chí được biểu diễn thông qua phần *Aims & Scope*. Dữ liệu đầu vào của bài toán do đó mang tính thuần văn bản và có độ dài lớn, đòi hỏi các mô hình có khả năng nắm bắt ngữ cảnh và quan hệ ngữ nghĩa phức tạp.

Bài toán khuyến nghị nộp bài báo khoa học (Paper Submission Recommendation) có thể được mô hình hóa như một bài toán xếp hạng (Learning to Rank) hoặc bài toán khớp nối ngữ nghĩa (Semantic Matching).

Giả sử chúng ta có tập hợp các tạp chí/hội nghị đích (venue candidates) là $\mathcal{V} = \{v_1, v_2, ..., v_M\}$, trong đó M là tổng số tạp chí khả dụng. Mỗi tạp chí v_j được biểu diễn bởi một tập hợp thông tin văn bản (ví dụ: mô tả phạm vi, danh sách bài báo đã xuất bản).

Một bài báo cần nộp P được biểu diễn bởi chuỗi văn bản $T_P = (t_1, t_2, ..., t_L)$, bao gồm tiêu đề và tóm tắt.

Mục tiêu của hệ thống là học một hàm đánh giá $f(P, v_j; \theta)$ trả về điểm số tương thích

(relevance score) $s_j \in \mathbb{R}$:

$$s_j = f(P, v_j; \theta) \tag{1}$$

Hệ thống sau đó sẽ sắp xếp các tạp chí theo thứ tự giảm dần của s_j và trả về danh sách Top-K tạp chí phù hợp nhất cho bài báo P:

$$\mathcal{R}_K(P) = \underset{\mathcal{S} \subset \mathcal{V}, |\mathcal{S}|=K}{\arg\max} \sum_{v_j \in \mathcal{S}} s_j \tag{2}$$

Thách thức chính của bài toán nằm ở việc:

- Văn bản khoa học thường dài và chứa nhiều thuật ngữ chuyên môn phức tạp.
- Sự nhập nhằng về ngữ nghĩa (ambiguity): Một từ khóa có thể có nghĩa khác nhau trong các ngữ cảnh khác nhau.
- Sự mất cân bằng dữ liệu: Một số tạp chí lớn có rất nhiều bài báo mẫu, trong khi các tạp chí nhỏ có ít dữ liệu hơn.

Các phương pháp truyền thống dựa trên biểu diễn tĩnh như TF-IDF hoặc word embedding (Word2Vec, GloVe, FastText) gặp hạn chế lớn trong việc hiểu ngữ cảnh học thuật và các thuật ngữ chuyên ngành, dẫn đến hiệu quả gợi ý chưa cao [19, 22]. Sự phát triển của các mô hình ngôn ngữ huấn luyện trước dựa trên Transformer, tiêu biểu là BERT và các biến thể của nó, đã mở ra hướng tiếp cận mới cho bài toán này [25, 8].

Trong số các biến thể của BERT, báo cáo này lựa chọn **DistilRoBERTa** làm mô hình ngôn ngữ nền tảng. DistilRoBERTa là phiên bản rút gọn của RoBERTa, giữ lại phần lớn khả năng biểu diễn ngữ nghĩa trong khi giảm đáng kể chi phí tính toán và bộ nhớ, phù hợp với các kịch bản huấn luyện và suy luận có tài nguyên hạn chế [26, 27]. Việc sử dụng DistilRoBERTa cho phép mô hình hóa hiệu quả các văn bản học thuật dài như Abstract và Aims & Scope, đồng thời đảm bảo khả năng triển khai thực tế.

Gần đây, SimCPSR đề xuất sử dụng học tương phản (contrastive learning) trên nền các mô hình Transformer để học embedding cho bài báo và hội nghị, sau đó thực hiện so khớp thông qua độ đo cosine similarity [13]. Cách tiếp cận này giúp cải thiện chất lượng embedding so với các phương pháp giám sát truyền thống và đạt được kết quả khả quan trong bài toán gợi ý nộp bài.

Tuy nhiên, SimCPSR và các phương pháp embedding-based tương tự vẫn dựa trên giả định rằng mức độ phù hợp giữa bài báo và hội nghị có thể được phản ánh đầy đủ thông qua so sánh embedding toàn cục. Giả định này bỏ qua các tương tác chi tiết ở mức token giữa nội dung bài báo và phạm vi nghiên cứu của hội nghị, vốn rất quan trọng trong các văn bản học thuật đa chủ đề.

Xuất phát từ hạn chế trên, báo cáo này xây dựng bài toán nghiên cứu theo hướng mở rộng các phương pháp dựa trên mô hình ngôn ngữ lớn bằng cách tích hợp cơ chế **Cross-Attention**. Thay vì chỉ so khớp embedding toàn cục, phương pháp đề xuất cho phép mô hình học trực tiếp tương tác token-level giữa bài báo và hội nghị, từ đó tập trung vào các phần nội dung có liên quan nhất [9, 12].

Tóm lại, bài toán nghiên cứu trong báo cáo được xây dựng với mục tiêu: (i) khai thác sức mạnh biểu diễn ngữ nghĩa của mô hình ngôn ngữ huấn luyện trước DistilRoBERTa, (ii) kế thừa ưu điểm của học tương phản trong SimCPSR, và (iii) khắc phục hạn chế của các phương pháp

embedding-based thông qua việc tích hợp Cross-Attention, nhằm nâng cao hiệu quả gợi ý nộp bài báo khoa học.

1.4 Sơ lược về các cách tiếp cận trong đề tài nghiên cứu

Dựa trên bài toán nghiên cứu đã xây dựng và các phân tích về hạn chế của những phương pháp hiện có, báo cáo này triển khai và so sánh các cách tiếp cận tiêu biểu cho bài toán gợi ý nộp bài báo khoa học, từ các mô hình cơ sở đến các phương pháp học sâu hiện đại.

Approach A - Phương pháp dựa trên biểu diễn tĩnh (Baseline): Cách tiếp cận này sử dụng các kỹ thuật biểu diễn văn bản truyền thống như TF-IDF hoặc word embedding tĩnh (Word2Vec, GloVe, FastText) để ánh xạ bài báo và hội nghị vào không gian vector. Độ phù hợp giữa bài báo và hội nghị được tính thông qua các độ đo tương đồng như cosine similarity. Mặc dù đơn giản và hiệu quả về mặt tính toán, các phương pháp này không nắm bắt được ngữ cảnh học thuật và các quan hệ ngữ nghĩa phức tạp giữa các thuật ngữ chuyên ngành, do đó chỉ được sử dụng làm mốc so sánh (baseline).

Approach B - Mô hình Transformer với so khớp embedding toàn cục: Trong cách tiếp cận này, các mô hình ngôn ngữ huấn luyện trước dựa trên Transformer như BERT, SciBERT hoặc DistilRoBERTa được sử dụng để trích xuất embedding ngữ cảnh cho bài báo và hội nghị. Mỗi thực thể được biểu diễn bởi một vector ngữ nghĩa dày đặc, và việc xếp hạng được thực hiện dựa trên độ tương đồng giữa các embedding toàn cục. Cách tiếp cận này cải thiện đáng kể khả năng hiểu nội dung văn bản so với các phương pháp truyền thống, tuy nhiên vẫn giả định rằng mức độ phù hợp có thể được biểu diễn đầy đủ bằng một vector tổng quát duy nhất.

Approach C - Học tương phản dựa trên embedding (SimCPSR): Kế thừa nền tảng Transformer-based, SimCPSR áp dụng kỹ thuật học tương phản (contrastive learning) để tinh chỉnh không gian embedding sao cho bài báo và hội nghị phù hợp được kéo gần nhau, trong khi các cặp không phù hợp bị đẩy ra xa. Cách tiếp cận này giúp mô hình học được cấu trúc ngữ nghĩa đặc thù cho bài toán gợi ý nộp bài và đã cho thấy hiệu quả vượt trội so với các mô hình giám sát truyền thống. Tuy nhiên, SimCPSR vẫn dựa trên việc so khớp embedding toàn cục và chưa khai thác được các tương tác chi tiết ở mức token.

Approach D - Phương pháp đề xuất dựa trên Cross-Attention: Đây là hướng tiếp cận chính và là đóng góp cốt lõi của báo cáo. Thay vì chỉ so sánh embedding toàn cục của bài báo và hội nghị, phương pháp đề xuất tích hợp cơ chế Cross-Attention để mô hình hóa trực tiếp tương tác giữa các token trong bài báo và các token trong phần *Aims & Scope* của hội nghị. Cách tiếp cận này cho phép mô hình tập trung vào các đoạn nội dung có liên quan nhất, nắm bắt tốt hơn các mối quan hệ ngữ nghĩa tinh tế và khắc phục hạn chế của các phương pháp embedding-based trước đó.

2 Cơ sở lý thuyết

Chương này trình bày hệ thống các kiến thức nền tảng phục vụ cho việc xây dựng và phân tích các phương pháp được sử dụng trong báo cáo. Nội dung chương tập trung vào các khái niệm cốt lõi trong xử lý ngôn ngữ tự nhiên, bao gồm biểu diễn văn bản, kiến trúc Transformer, học tương phản (contrastive learning) và cơ chế Cross-Attention.

2.1 Biểu diễn văn bản trong xử lý ngôn ngữ tự nhiên

Biểu diễn văn bản là bước nền tảng trong các bài toán xử lý ngôn ngữ tự nhiên (NLP). Mục tiêu của biểu diễn văn bản là ánh xạ chuỗi ký tự đầu vào thành các vector trong không gian liên tục, sao cho khoảng cách hình học giữa các vector phản ánh mức độ tương đồng ngữ nghĩa giữa các văn bản.

2.1.1 Biểu diễn dựa trên từ (Word-level Representation)

Các phương pháp biểu diễn văn bản truyền thống thường dựa trên mức từ, trong đó mỗi từ được ánh xạ thành một vector cố định chiều. Các mô hình tiêu biểu bao gồm Word2Vec, GloVe và FastText [21, 22].

FastText mở rộng Word2Vec bằng cách sử dụng thông tin subword, cho phép xử lý tốt hơn các từ hiếm và biến thể hình thái. Biểu diễn của một văn bản thường được xây dựng bằng cách tổng hợp (ví dụ: trung bình hoặc tổng có trọng số) các vector từ thành phần.

Hạn chế cốt lõi của nhóm phương pháp này là tính **phi ngữ cảnh**: mỗi từ chỉ có một biểu diễn duy nhất, bất kể ngữ cảnh sử dụng. Điều này đặc biệt bất lợi trong các văn bản học thuật, nơi một thuật ngữ có thể mang ý nghĩa khác nhau tùy theo lĩnh vực.

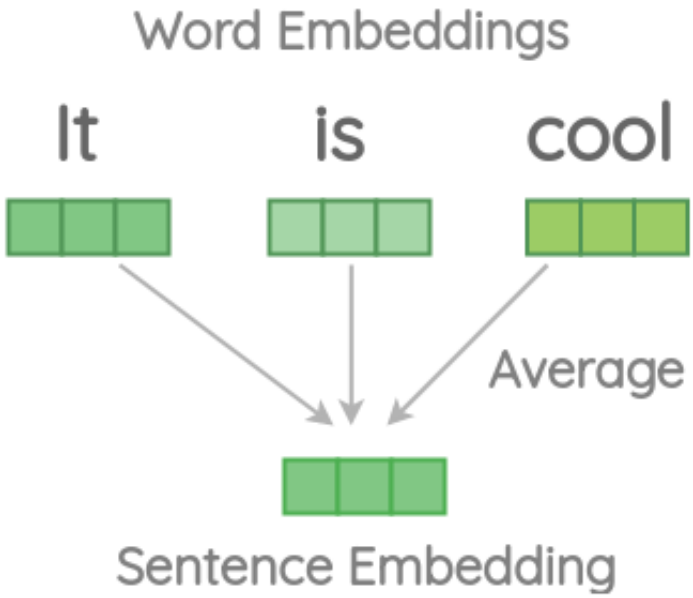

Hình 1: Minh họa biểu diễn embedding tĩnh ở mức từ và phép trung bình để tạo embedding cho câu (Nguồn: [29]).

2.1.2 Biểu diễn dựa trên thống kê

Trước khi các mô hình embedding dựa trên học sâu ra đời, các phương pháp biểu diễn văn bản chủ yếu dựa trên thống kê tần suất từ, tiêu biểu là Bag-of-Words (BoW) và TF-IDF.

TF-IDF (Term Frequency - Inverse Document Frequency) là phương pháp thống kê nhằm đánh giá tầm quan trọng của một từ trong văn bản.

$$W_{t,d} = TF_{t,d} \times \log\left(\frac{N}{DF_t}\right) \tag{3}$$

Trong đó:

- $TF_{t,d}$ là tần suất từ t trong văn bản d
- N là tổng số văn bản, và DF_t là số văn bản chứa từ t.
- TF-IDF giúp giảm trọng số của các từ xuất hiện quá phổ biến (như "the", "a") và tăng trọng số cho các từ đặc trưng.

Trong các phương pháp này, mỗi văn bản được biểu diễn dưới dạng một vector có chiều bằng kích thước từ vựng, trong đó mỗi phần tử phản ánh mức độ xuất hiện của một từ trong văn bản.

Mặc dù đơn giản và dễ triển khai, các phương pháp này tồn tại nhiều hạn chế nghiêm trọng, bao gồm không mô hình hóa được thứ tự từ, không nắm bắt được ngữ nghĩa và không thể biểu diễn các mối quan hệ ngữ cảnh phức tạp. Do đó, các phương pháp dựa trên thống kê không phù hợp cho các bài toán gợi ý học thuật có nội dung chuyên sâu như gợi ý nộp bài báo khoa học [19].

2.1.3 Biểu diễn ngữ cảnh (Contextualized Representation)

Các mô hình ngôn ngữ hiện đại như BERT và RoBERTa khắc phục hạn chế trên bằng cách sinh ra biểu diễn phụ thuộc ngữ cảnh [25, 26]. Trong các mô hình này, biểu diễn của một token được xác định bởi toàn bộ chuỗi đầu vào thông qua cơ chế attention.

Biểu diễn ngữ cảnh cho phép mô hình nắm bắt được sự khác biệt ngữ nghĩa tinh tế giữa các cách sử dụng khác nhau của cùng một từ. Đây là nền tảng cho các phương pháp dựa trên Transformer được sử dụng trong báo cáo, bao gồm Approach B, Approach C và phương pháp đề xuất.

2.1.4 So sánh biểu diễn tĩnh và biểu diễn ngữ cảnh

Biểu diễn từ truyền thống như Word2Vec, GloVe và FastText được xem là biểu diễn tĩnh (static embedding), trong đó mỗi từ được ánh xạ vào một vector cố định, không phụ thuộc vào ngữ cảnh xuất hiện. Điều này dẫn đến việc một từ đa nghĩa chỉ có một biểu diễn duy nhất, làm giảm khả năng phân biệt ngữ nghĩa trong các văn bản học thuật phức tạp.

Ngược lại, các mô hình ngôn ngữ dựa trên Transformer tạo ra biểu diễn ngữ cảnh (contextualized embedding), trong đó biểu diễn của một token phụ thuộc vào toàn bộ chuỗi văn bản đầu vào. Cách tiếp cận này đặc biệt phù hợp cho các bài toán yêu cầu hiểu sâu nội dung, chẳng hạn như so khớp giữa bài báo và phạm vi nghiên cứu của hội nghị [25].

2.2 Kiến trúc Transformer

Transformer là kiến trúc học sâu dựa hoàn toàn trên cơ chế attention, được giới thiệu bởi Vaswani et al. [8]. Khác với các kiến trúc tuần tự như RNN hay LSTM, Transformer cho phép xử lý song song và mô hình hóa phụ thuộc dài hạn hiệu quả hơn.

2.2.1 Multi-head Attention

Trong kiến trúc Transformer, thay vì sử dụng một phép attention duy nhất, mô hình áp dụng cơ chế Multi-head Attention, cho phép học đồng thời nhiều không gian chú ý khác nhau. Mỗi head attention tập trung vào một khía cạnh ngữ nghĩa riêng biệt của chuỗi văn bản, từ đó giúp mô hình nắm bắt được các mối quan hệ đa chiều giữa các token.

Multi-head Attention mở rộng cơ chế trên bằng cách ánh xạ Q, K, V vào h không gian con khác nhau thông qua các ma trận trọng số học được:

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \tag{4}$$

Trong đó W_i^Q, W_i^K, W_i^V là các ma trận chiếu tuyến tính của head thứ i. Các head sau đó được nối (concatenate) và chiếu tuyến tính lại để tạo ra đầu ra cuối cùng:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \ldots, \text{head}_h)W^O \tag{5}$$

Multi-head Attention đóng vai trò quan trọng trong việc tạo ra biểu diễn ngữ cảnh giàu thông tin, là nền tảng cho các cơ chế tương tác nâng cao như Cross-Attention được trình bày trong phần sau [8].

2.2.2 Cơ chế Self-Attention

Self-Attention cho phép mỗi token trong chuỗi văn bản tương tác trực tiếp với tất cả các token còn lại.

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{6}$$

Trong đó:

- $Q \in \mathbb{R}^{N \times d_k}$: Ma trận truy vấn.
- $K \in \mathbb{R}^{M \times d_k}$: Ma trận khóa.
- $V \in \mathbb{R}^{M \times d_v}$: Ma trận giá trị.
- d_k: Kích thước chiều sâu của vector Key (dùng để chuẩn hóa).
- QK^T: Phép nhân giữa ma trận Query và Key. Kết quả của phép tính này là một ma trận điểm số (attention scores), thể hiện mức độ tương đồng giữa Q và K. Nếu điểm số càng cao thì mô hình càng **chú ý** nhiều vào vị trí đó.
- Softmax: Hàm chuẩn hóa để chuyển đổi các điểm số thành xác suất (trọng số) nằm trong khoảng $[0, 1]$.

- $\sqrt{d_k}$: Hệ số tỷ lệ (scaling factor) dùng để chuẩn hoá giúp ổn định gradient trong quá trình huấn luyện, tránh việc ảnh hưởng tới hàm Softmax. Khi dữ liệu đầu vào quá lớn, phương sai lớn thì hàm Softmax sẽ cho ra trọng số rất lớn, ngược lại khi các dữ liệu đầu vào nhỏ thì hàm Softmax sẽ cho ra các trọng số nhỏ.

Cơ chế này giúp mô hình học được mối quan hệ ngữ nghĩa toàn cục, đồng thời giảm thiểu các vấn đề về suy giảm gradient thường gặp trong các mô hình tuần tự.

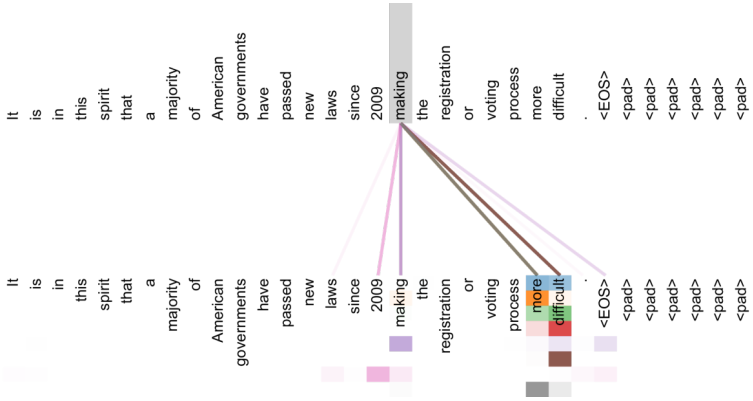

Hình 2: Minh họa ma trận self-attention thể hiện mức độ chú ý giữa các token trong cùng một câu. (Nguồn: [8])

2.2.3 Encoder Transformer

Encoder Transformer bao gồm nhiều tầng xếp chồng, mỗi tầng gồm một khối self-attention và một khối feed-forward. Trong báo cáo này, các encoder huấn luyện trước như DistilRoBERTa được sử dụng để trích xuất biểu diễn token-level cho văn bản học thuật.

Các biểu diễn này đóng vai trò đầu vào cho các cơ chế so khớp và tương tác được trình bày trong Chương 3.

2.3 Học tương phản (Contrastive Learning)

Học tương phản là khung học biểu diễn trong đó mô hình được huấn luyện để kéo gần các cặp dữ liệu tương đồng và đẩy xa các cặp không tương đồng trong không gian embedding.

Trong bài toán gợi ý nộp bài, học tương phản cho phép mô hình học biểu diễn sao cho bài báo và hội nghị phù hợp nằm gần nhau hơn so với các cặp không phù hợp, ngay cả khi số lượng nhãn giám sát hạn chế.

2.3.1 Contrastive Learning trong bài toán matching

Không giống các bài toán phân loại truyền thống, bài toán gợi ý nộp bài báo khoa học mang bản chất của một bài toán matching, trong đó mục tiêu là đánh giá mức độ phù hợp giữa hai thực thể khác nhau: bài báo và hội nghị. Học tương phản đặc biệt phù hợp cho loại bài toán này do khả năng học không gian embedding phân biệt các cặp phù hợp và không phù hợp.

Trong SimCPSR, học tương phản được sử dụng để kéo gần embedding của các cặp bài báo–hội nghị phù hợp và đẩy xa các cặp không phù hợp. Tuy nhiên, phương pháp này vẫn giả định rằng mối quan hệ giữa hai thực thể có thể được phản ánh đầy đủ thông qua embedding toàn cục [13].

2.3.2 Hàm mất mát tương phản

Để học không gian biểu diễn chung cho bài báo và tạp chí, nghiên cứu này sử dụng hàm mất mát tương phản **InfoNCE**, vốn được áp dụng rộng rãi trong các phương pháp Contrastive Learning.

Giả sử h_i là embedding của bài báo thứ i, h_i^+ là embedding của tạp chí đúng (positive sample) tương ứng, và $\{h_j\}_{j=1}^B$ là tập các embedding tạp chí trong cùng một mini-batch có kích thước B (bao gồm cả positive và các negative samples). Hàm mất mát được định nghĩa như sau:

$$\mathcal{L}_{\text{contrastive}} = -\log \frac{\exp(\text{sim}(h_i, h_i^+)/\tau)}{\sum_j \exp(\text{sim}(h_i, h_j)/\tau)} \tag{7}$$

Trong đó:

- h_i là vector biểu diễn của bài báo thứ i,
- h_i^+ là vector biểu diễn của tạp chí đúng tương ứng,
- h_j là các vector tạp chí trong mini-batch (được xem là negative samples khi $j \neq i$),
- $\text{sim}(\cdot, \cdot)$ là hàm đo độ tương đồng, thường sử dụng độ tương đồng Cosine:

$$\text{sim}(a, b) = \frac{a \cdot b}{\|a\|\|b\|} \tag{8}$$

- $\tau > 0$ là tham số nhiệt độ (temperature), điều chỉnh độ sắc của phân phối xác suất; giá trị τ nhỏ làm tăng mức phân biệt giữa positive và negative samples.

Hàm mất mát trên khuyến khích mô hình kéo gần embedding của bài báo và tạp chí đúng trong không gian vector, đồng thời đẩy xa các cặp không phù hợp trong cùng mini-batch. Nhờ cơ chế này, mô hình học được một không gian biểu diễn đặc thù cho bài toán khuyến nghị nộp bài, thay vì chỉ dựa vào embedding tiền huấn luyện ban đầu.

Học tương phản là nền tảng của Approach C (SimCPSR) và đóng vai trò quan trọng trong việc cải thiện chất lượng embedding trước khi thực hiện so khớp.

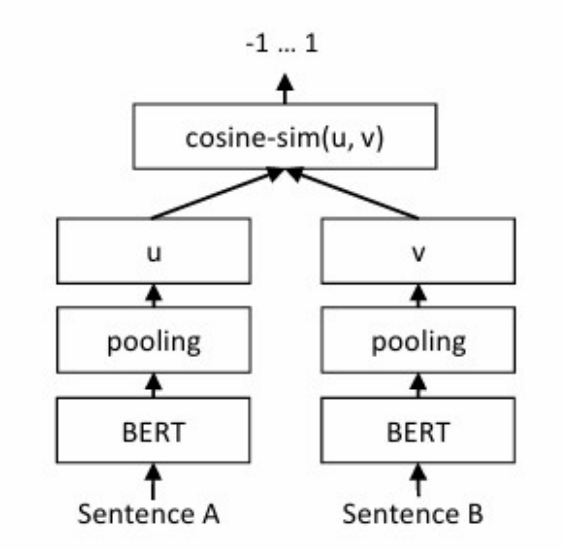

Hình 3: Minh họa kiến trúc Sentence-BERT cho bài toán so khớp câu, trong đó hai câu được mã hóa độc lập bằng BERT, sau đó so sánh bằng độ đo cosine similarity trong khoảng $[-1, 1]$. (Nguồn: [11])

2.3.3 Vai trò của tham số nhiệt độ trong học tương phản

Trong hàm mất mát tương phản, tham số nhiệt độ τ (temperature) đóng vai trò điều chỉnh độ "sắc nét" của phân phối xác suất sinh ra bởi hàm softmax. Cụ thể, τ kiểm soát mức độ nhấn mạnh sự khác biệt giữa các cặp dữ liệu tương đồng (positive pairs) và không tương đồng (negative pairs) trong không gian embedding.

Khi τ có giá trị nhỏ, hàm softmax trở nên sắc nét hơn, khiến mô hình tập trung mạnh vào các cặp positive có độ tương đồng cao nhất và đẩy xa các negative pairs một cách quyết liệt. Ngược lại, khi τ lớn, phân phối softmax trở nên mượt hơn, làm giảm mức độ phân biệt giữa các cặp dữ liệu và có thể dẫn đến biểu diễn kém phân tách.

Trong bối cảnh học tương phản cho bài toán matching, việc lựa chọn giá trị τ phù hợp là yếu tố quan trọng nhằm cân bằng giữa khả năng phân biệt ngữ nghĩa và tính ổn định trong huấn luyện. Tham số này thường được cố định trong quá trình huấn luyện và được lựa chọn dựa trên thực nghiệm, như được áp dụng trong các mô hình học tương phản tiêu biểu như Sentence-BERT và SimCPSR [11, 13].

Trong báo cáo này, tham số nhiệt độ được xem là một thành phần lý thuyết của hàm mất mát tương phản và sẽ không được tinh chỉnh sâu trong giai đoạn thực nghiệm, nhằm tập trung đánh giá tác động của kiến trúc và cơ chế tương tác giữa bài báo và hội nghị.

2.4 Cơ chế Cross-Attention

Mặc dù học tương phản cải thiện đáng kể chất lượng embedding, các phương pháp embedding-based vẫn giả định rằng mối quan hệ giữa hai thực thể có thể được phản ánh thông qua so sánh vector toàn cục. Giả định này không luôn đúng trong các bài toán yêu cầu so khớp chi tiết.

Cross-Attention được đề xuất nhằm mô hình hóa tương tác trực tiếp giữa hai chuỗi văn bản khác nhau [9, 12].

2.4.1 So sánh Self-Attention và Cross-Attention

Self-Attention mô hình hóa mối quan hệ nội tại giữa các token trong cùng một chuỗi văn bản, trong khi Cross-Attention cho phép mô hình hóa tương tác giữa hai chuỗi văn bản khác nhau. Do đó, Cross-Attention đặc biệt phù hợp cho các bài toán so khớp, truy hồi và gợi ý.

Trong bối cảnh bài toán gợi ý nộp bài báo khoa học, Self-Attention giúp học biểu diễn nội dung bài báo và hội nghị một cách độc lập, trong khi Cross-Attention cho phép mô hình tập trung vào các thành phần nội dung của bài báo liên quan nhất đến phạm vi nghiên cứu của hội nghị. Sự khác biệt này là cơ sở lý thuyết cho phương pháp đề xuất trong báo cáo [12].

2.4.2 Định nghĩa Cross-Attention

Trong báo cáo này, biểu diễn của bài báo đóng vai trò Query, trong khi biểu diễn của hội nghị hoặc tạp chí đóng vai trò Key và Value.

Giả sử $Q_{\text{paper}} \in \mathbb{R}^{n \times d}$ là ma trận biểu diễn của bài báo gồm n token, và $K_{\text{journal}}, V_{\text{journal}} \in \mathbb{R}^{m \times d}$ là biểu diễn của tạp chí gồm m token, Cross-Attention được định nghĩa như sau:

$$\text{Attention}\big(Q_{\text{paper}}, K_{\text{journal}}, V_{\text{journal}}\big) = \text{softmax}\left(\frac{Q_{\text{paper}} K_{\text{journal}}^T}{\sqrt{d_k}}\right) V_{\text{journal}} \tag{9}$$

Trong đó d_k là chiều của vector Key. Ma trận trọng số attention thu được phản ánh mức độ liên quan giữa từng token trong bài báo và từng token trong mô tả tạp chí.

2.4.3 Hàm score trong Cross-Attention

$$\text{score}\big(Q_{\text{paper}}, K_{\text{journal}}\big) = \frac{Q_{\text{paper}} K_{\text{journal}}^T}{\sqrt{d_k}} \tag{10}$$

Hàm score này sẽ được sử dụng trực tiếp trong Chương 3 khi mô tả pipeline của phương pháp đề xuất, mà không cần giải thích lại chi tiết.

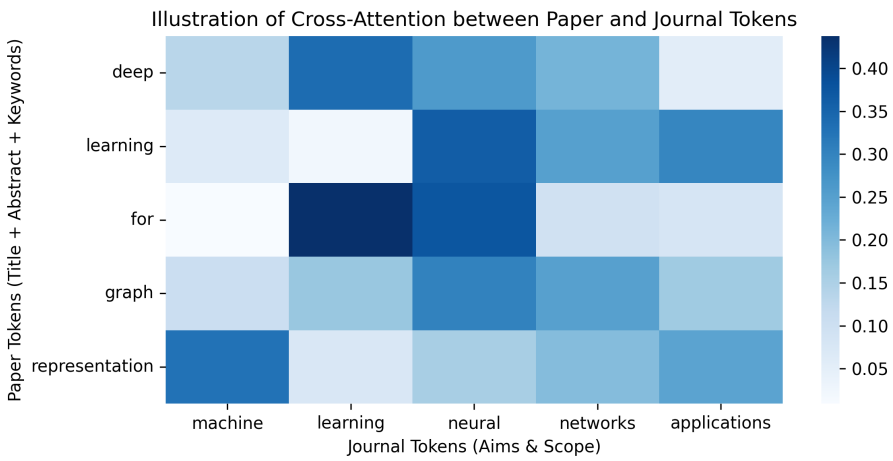

Hình 4: Minh họa cơ chế cross-attention giữa các token của bài báo (Paper) và các token mô tả hội nghị hoặc tạp chí (Journal). Mỗi ô biểu diễn mức độ chú ý của một token trong bài báo đối với một token trong phần Aims & Scope.

2.5 Tổng kết chương

Chương này đã trình bày hệ thống các khái niệm nền tảng liên quan đến biểu diễn văn bản, kiến trúc Transformer, học tương phản và cơ chế Cross-Attention. Các phân tích và công thức trong chương này tạo nền tảng lý thuyết vững chắc cho các phương pháp và pipeline được trình bày trong Chương 3.

3 Phương pháp thí nghiệm

Chương này trình bày chi tiết các phương pháp nghiên cứu và pipeline xử lý được sử dụng trong luận văn nhằm giải quyết bài toán gợi ý nộp bài báo khoa học. Trọng tâm của chương không nằm ở việc trình bày lại các công thức toán học nền tảng, mà tập trung vào mô tả cách các thành phần trong hệ thống được thiết kế, kết nối và triển khai trong thực tế.

Cụ thể, chương này mô tả quy trình xử lý dữ liệu từ đầu vào văn bản thô đến đầu ra là danh sách gợi ý Top-K hội nghị hoặc tạp chí phù hợp. Các phương pháp được trình bày theo tiến trình phát triển, bao gồm phương pháp cơ sở truyền thống, các mô hình dựa trên Transformer, phương pháp embedding-based contrastive learning và cuối cùng là phương pháp đề xuất dựa trên Cross-Attention.[23, 8]

Các công thức toán học chi tiết liên quan đến Transformer, học tương phản và Cross-Attention đã được trình bày trong Chương 2. Trong chương này, các công thức đó chỉ được viện dẫn lại khi cần thiết để làm rõ pipeline và thuật toán, nhằm tránh lặp lại nội dung lý thuyết.

3.1 Tiền xử lý dữ liệu

3.1.1 Cấu trúc dữ liệu đầu vào

Mỗi mẫu dữ liệu trong bài toán gợi ý nộp bài báo khoa học bao gồm hai thành phần chính: (i) thông tin của bài báo khoa học và (ii) thông tin mô tả hội nghị hoặc tạp chí mà bài báo có thể được nộp tới.

Thông tin của bài báo được biểu diễn thông qua các trường văn bản sau:

- **Title (T)**: tiêu đề bài báo, phản ánh chủ đề chính của nghiên cứu.
- **Abstract (A)**: phần tóm tắt, cung cấp mô tả chi tiết về mục tiêu, phương pháp và kết quả nghiên cứu.
- **Keywords (K)**: danh sách từ khóa do tác giả cung cấp, nhấn mạnh các khái niệm quan trọng của bài báo.

Thông tin của hội nghị hoặc tạp chí được biểu diễn thông qua trường:

- **Aims & Scope (S)**: mô tả phạm vi nghiên cứu, các chủ đề quan tâm và định hướng học thuật của hội nghị hoặc tạp chí.

Các trường văn bản này được sử dụng nhất quán cho tất cả các phương pháp nhằm đảm bảo tính công bằng trong quá trình so sánh thực nghiệm.

3.1.2 Quy trình tiền xử lý văn bản

Dữ liệu văn bản thô thường chứa nhiều nhiễu như ký tự đặc biệt, sự không nhất quán về định dạng và các từ ít mang ý nghĩa ngữ nghĩa. Do đó, một quy trình tiền xử lý thống nhất được áp dụng trước khi đưa dữ liệu vào các mô hình học máy và học sâu.

Quy trình tiền xử lý trong luận văn bao gồm các bước sau:

1. **Chuẩn hóa chữ viết**: toàn bộ văn bản được chuyển về chữ thường nhằm tránh sự khác biệt không cần thiết giữa các token.
2. **Loại bỏ ký tự đặc biệt và dấu câu**: các ký tự không mang ý nghĩa ngữ nghĩa được loại bỏ để giảm nhiễu.
3. **Loại bỏ ký tự không thuộc bảng chữ cái**: chỉ giữ lại các token dạng chữ để tập trung vào nội dung ngữ nghĩa.
4. **Loại bỏ stopwords**: sử dụng danh sách stopwords chuẩn để loại bỏ các từ xuất hiện thường xuyên nhưng ít mang thông tin.
5. **Chuẩn hóa khoảng trắng**: loại bỏ khoảng trắng dư thừa nhằm đảm bảo tính nhất quán của chuỗi văn bản.

Bảng 1: Ví dụ cho quá trình tiền xử lý dữ liệu

Before	**After**
Microbiological synthesis of 7α- and 7β-hydroxy derivatives of testolactone	microbiological synthesis hydroxy derivatives testolactone
A design methodology is proposed in this study in which the process simulator Aspen HYSYS® is linked with an optimization algorithm available in MATLAB®	design methodology proposed study process simulator aspen hysys linked optimization algorithm available matlab
The effects of the "baffles - deceleration strip" hybrid protection system was discussed in detail with the nails number and nails angle	effects baffles deceleration strip hybrid protection discussed nails number nails angle

Quy trình tiền xử lý này được áp dụng đồng nhất cho tất cả các cách tiếp cận nhằm đảm bảo rằng sự khác biệt về kết quả thực nghiệm đến từ kiến trúc mô hình, thay vì từ sự khác nhau trong xử lý dữ liệu.

3.1.3 Tổ hợp đặc trưng đầu vào

Để đánh giá mức độ đóng góp của từng nguồn thông tin, các trường văn bản được kết hợp thành nhiều tổ hợp đặc trưng khác nhau. Cụ thể, các tổ hợp được sử dụng trong luận văn bao gồm: T, A, K, TA, AK, TK, TAK và TAKS.

Các tổ hợp này được sử dụng xuyên suốt cho tất cả các phương pháp từ Approach A đến Approach D. Việc giữ nguyên các tổ hợp đặc trưng giúp đảm bảo tính công bằng và khả năng so sánh trực tiếp giữa các phương pháp khác nhau.

3.1.4 Xây dựng biểu diễn đầu vào cho các phương pháp

Mặc dù sử dụng cùng một tập dữ liệu và các trường văn bản đầu vào, mỗi phương pháp trong luận văn xây dựng biểu diễn đầu vào theo cách khác nhau, phù hợp với đặc điểm kiến trúc của từng mô hình. Việc mô tả chi tiết cách xây dựng biểu diễn đầu vào là cần thiết nhằm làm rõ luồng dữ liệu trong pipeline và đảm bảo tính nhất quán trong so sánh thực nghiệm.

Đối với các phương pháp embedding-based truyền thống, cụ thể là Approach A và Approach C, mỗi trường văn bản (Title, Abstract, Keywords và Aims & Scope) được xử lý độc lập để tạo ra các vector biểu diễn toàn cục. Các vector này có thể được kết hợp thông qua phép nối (concatenation) hoặc các phép tổng hợp tuyến tính nhằm tạo ra biểu diễn cuối cùng cho bài báo và hội nghị. Cách tiếp cận này cho phép mô hình hoạt động với biểu diễn có chiều cố định và chi phí tính toán thấp, tuy nhiên không giữ lại được cấu trúc tuần tự của văn bản.

Ngược lại, đối với các phương pháp dựa trên Transformer như Approach B và Approach D, văn bản đầu vào được giữ nguyên dưới dạng chuỗi token nhằm bảo toàn thông tin ngữ cảnh. Trong luận văn này, các trường Title, Abstract và Keywords của bài báo được nối thành một chuỗi văn bản duy nhất, trong đó các token phân tách đặc biệt được sử dụng để đánh dấu ranh giới giữa các trường. Cách biểu diễn này cho phép mô hình học được mối quan hệ ngữ nghĩa giữa các thành phần khác nhau của bài báo.

Đối với thông tin hội nghị hoặc tạp chí, trường Aims & Scope được sử dụng làm nguồn dữ liệu chính và được đưa trực tiếp vào encoder của mô hình. Việc tách riêng biểu diễn của bài báo và hội nghị ở giai đoạn đầu giúp mô hình linh hoạt trong việc áp dụng các cơ chế tương tác khác nhau ở các bước tiếp theo của pipeline.

Chiến lược xây dựng biểu diễn đầu vào được giữ nhất quán cho tất cả các phương pháp nhằm đảm bảo rằng sự khác biệt về kết quả thực nghiệm phản ánh đúng tác động của kiến trúc mô hình, thay vì xuất phát từ sự khác nhau trong cách xử lý dữ liệu đầu vào.

3.2 Tổng quan pipeline hệ thống

Chương này trình bày chi tiết pipeline xử lý và huấn luyện của các phương pháp được sử dụng trong luận văn nhằm giải quyết bài toán gợi ý nộp bài báo khoa học. Trọng tâm của chương không nằm ở việc phân tích sâu các công thức toán học, mà tập trung vào cách các thành phần trong hệ thống được kết nối, luồng dữ liệu giữa các module, cũng như các quyết định thiết kế kiến trúc.

Hình 5 minh họa pipeline tổng thể của hệ thống gợi ý nộp bài, bao gồm các giai đoạn: tiền xử lý dữ liệu, trích xuất đặc trưng, huấn luyện mô hình và suy luận (inference) để đưa ra danh sách gợi ý Top-K hội nghị hoặc tạp chí phù hợp.

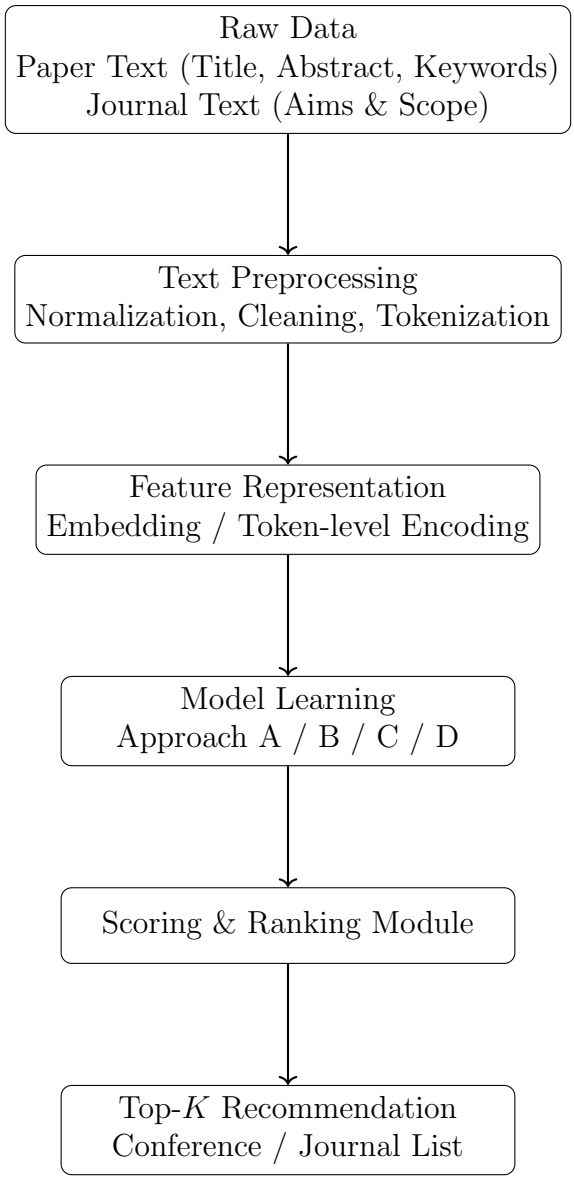

Hình 5: Pipeline tổng thể của hệ thống gợi ý nộp bài

3.3 Dữ liệu và tổ hợp đặc trưng

3.3.1 Nguồn dữ liệu và cấu trúc mẫu

Mỗi mẫu dữ liệu bao gồm một bài báo khoa học và nhãn tương ứng là hội nghị hoặc tạp chí mà bài báo đó đã được chấp nhận. Thông tin bài báo được biểu diễn thông qua các trường Title, Abstract và Keywords, trong khi thông tin hội nghị hoặc tạp chí được biểu diễn thông qua trường Aims & Scope.

3.3.2 Tổ hợp đặc trưng

Để đánh giá mức độ ảnh hưởng của từng nguồn thông tin, các trường văn bản được kết hợp thành nhiều tổ hợp khác nhau như T, A, K, TA, AK, TK, TAK và TAKS. Các tổ hợp này được sử dụng nhất quán cho tất cả các cách tiếp cận nhằm đảm bảo tính công bằng trong so sánh thực nghiệm.

3.4 Approach A – Phương pháp cơ sở (Baseline)

3.4.1 Pipeline xử lý

Approach A sử dụng các kỹ thuật embedding truyền thống dựa trên từ, cụ thể là FastText. Pipeline của Approach A được mô tả trong Hình 6.[22]

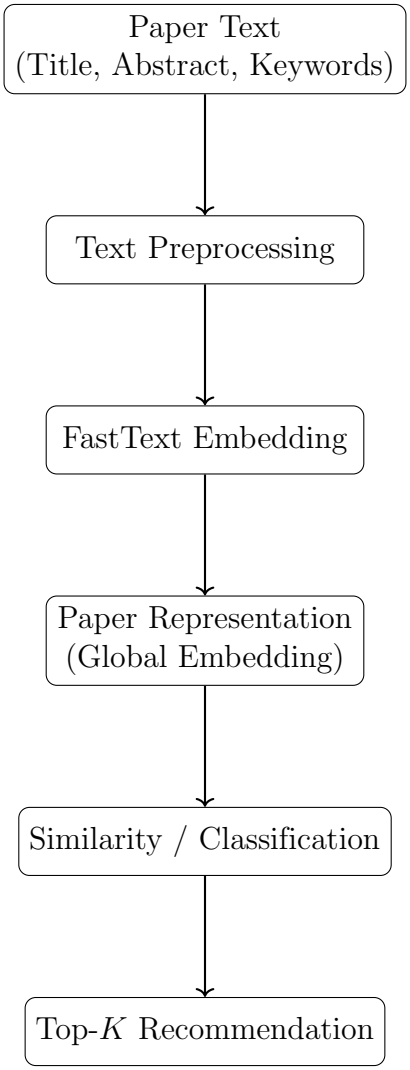

Hình 6: Pipeline của Approach A (FastText-based baseline)

3.4.2 Thuật toán huấn luyện

Algorithm 1 Huấn luyện mô hình Baseline (Approach A)

Require: Tập dữ liệu $D = \{(paper_i, venue_i)\}$
Ensure: Mô hình phân loại đã huấn luyện
1: **for** each $(paper, venue)$ in D **do**
2: Tiền xử lý văn bản *paper*
3: Trích xuất embedding FastText
4: Cập nhật tham số mô hình phân loại
5: **end for**

3.4.3 Nhận xét

Approach A có ưu điểm về chi phí tính toán thấp nhưng không mô hình hóa được ngữ cảnh dài và mối quan hệ ngữ nghĩa phức tạp.

3.5 Approach B – Transformer-based Pipeline

3.5.1 Pipeline xử lý

Approach B thay thế FastText bằng DistilRoBERTa nhằm cải thiện khả năng biểu diễn ngữ nghĩa. Pipeline bao gồm các bước: tokenization, encoding và classification.[25, 26]

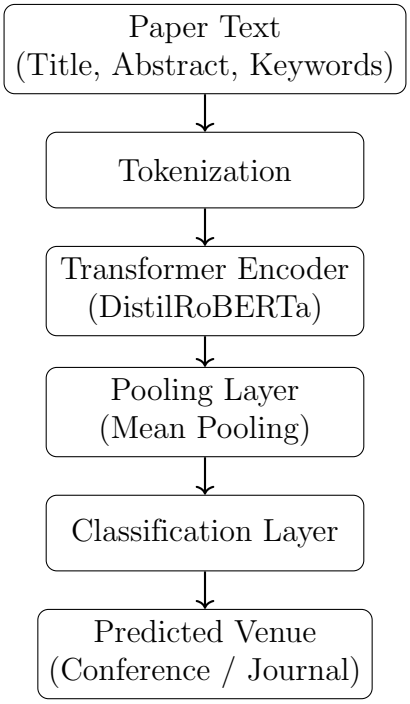

Hình 7: Pipeline của Approach B dựa trên Transformer

3.5.2 Chiến lược pooling

Embedding đầu ra có thể được lấy từ token [CLS] hoặc thông qua mean pooling. Trong luận văn này, mean pooling được ưu tiên do tính ổn định trong các bài toán biểu diễn văn bản dài.[11]

3.6 Approach C – Embedding-based Contrastive Learning (SimCPSR)[13]

3.6.1 Huấn luyện hai giai đoạn

Approach C sử dụng pipeline hai giai đoạn gồm huấn luyện học tương phản và huấn luyện downstream.

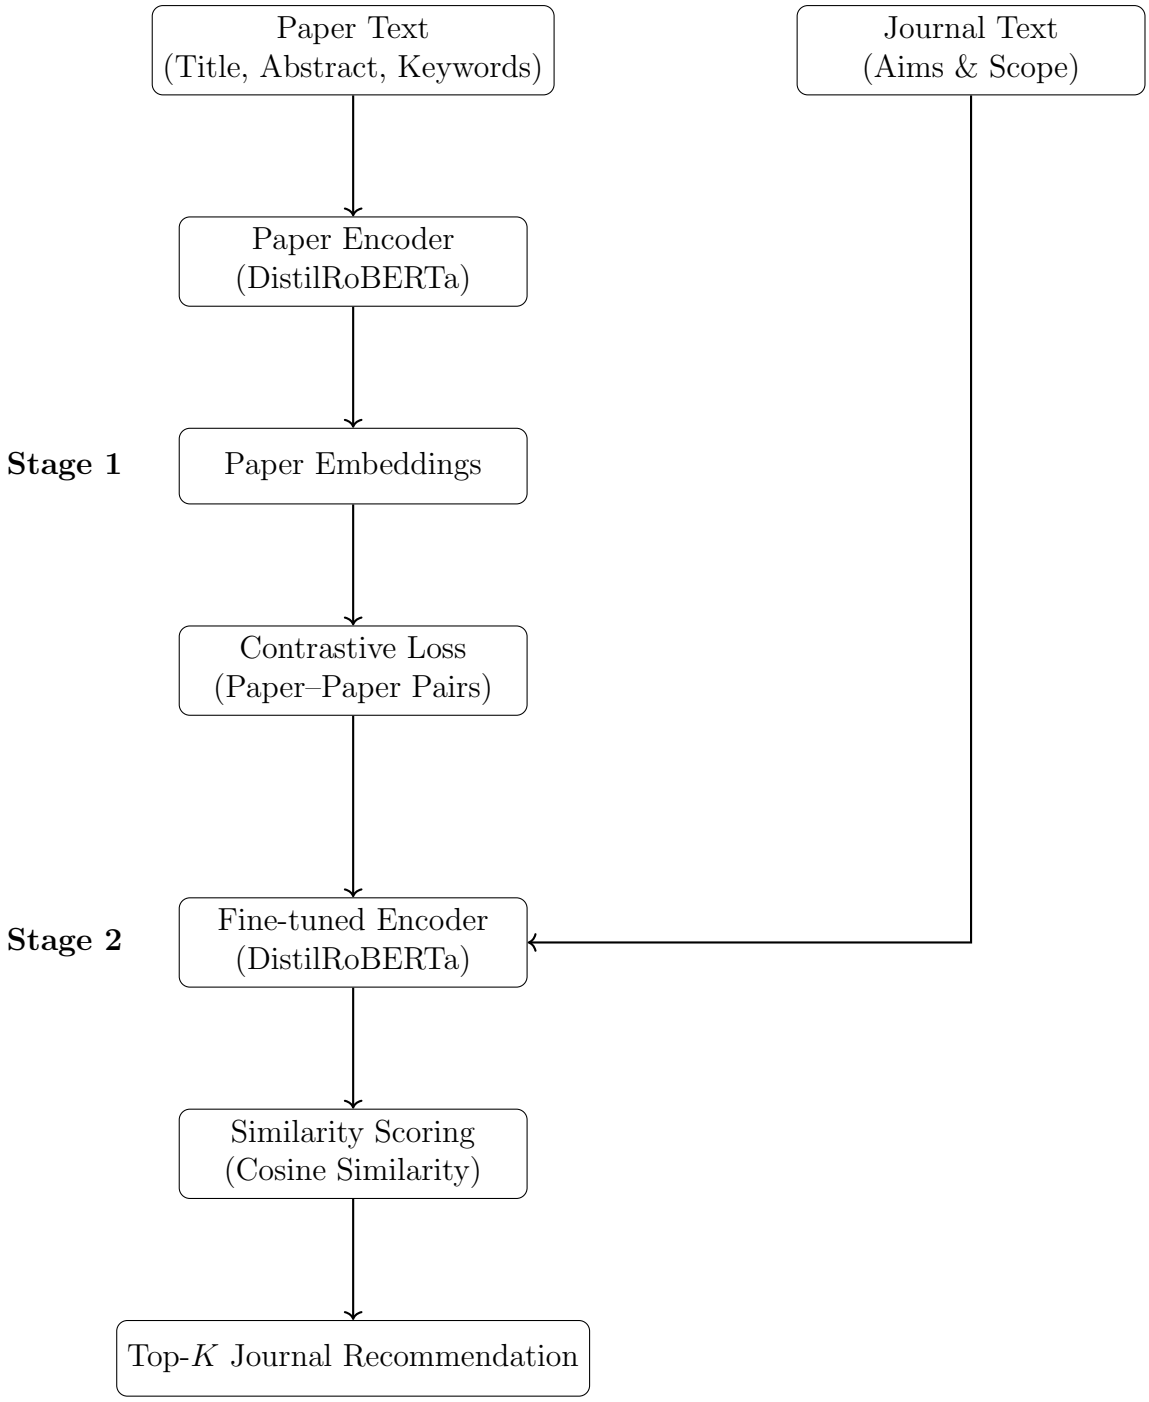

Hình 8: Pipeline hai giai đoạn của phương pháp SimCPSR (Approach C). Giai đoạn đầu áp dụng contrastive learning trên biểu diễn bài báo (TAK), trong khi thông tin Aims & Scope chỉ được sử dụng ở giai đoạn khớp sau thông qua độ đo cosine.

3.6.2 Thuật toán huấn luyện

Algorithm 2 Huấn luyện và suy luận mô hình Contrastive Learning (Approach C)

Require: Tập dữ liệu bài báo D, tập tạp chí J với Aims & Scope
Ensure: Danh sách Top-K tạp chí được gợi ý cho mỗi bài báo

```
Stage 1: Contrastive Representation Learning
for each mini-batch B ⊂ D do
    Xây dựng các cặp positive và negative từ B
    Tính embedding cho từng cặp bằng encoder E
    Tối ưu encoder E bằng hàm mất mát tương phản
end for
Stage 2: Journal Recommendation
for each bài báo p ∈ D do
    e_p ← E(p)
    for each tạp chí j ∈ J do
        e_j ← E(aims_j)
        s_j ← cosine_similarity(e_p, e_j)
    end for
    Trả về Top-K tạp chí có điểm s_j cao nhất
end for
```

3.6.3 Hạn chế

Mặc dù cải thiện chất lượng embedding, Approach C vẫn dựa trên so sánh embedding tĩnh.

Hạn chế cốt lõi của cách tiếp cận này là giả định rằng mối quan hệ giữa bài báo và hội nghị có thể được phản ánh đầy đủ thông qua so sánh embedding toàn cục, đây cũng là giả định chung của các phương pháp embedding-based như SimCPSR.

3.7 Phân tích pipeline và vai trò của từng phương pháp

Phần này trình bày vai trò của từng phương pháp trong pipeline tổng thể của hệ thống gợi ý nộp bài, đồng thời phân tích sự khác biệt về cách xử lý dữ liệu và mô hình hóa mối quan hệ giữa bài báo và hội nghị. Việc phân tích này giúp làm rõ tiến trình phát triển từ các phương pháp cơ sở đến phương pháp đề xuất, cũng như vai trò của từng cách tiếp cận trong việc đánh giá hiệu quả của hệ thống.

3.7.1 Vai trò của Approach A trong pipeline

Approach A đóng vai trò là phương pháp cơ sở (baseline) trong luận văn. Pipeline của phương pháp này sử dụng các kỹ thuật embedding truyền thống để biểu diễn văn bản dưới dạng vector toàn cục, sau đó áp dụng các mô hình phân loại hoặc so khớp đơn giản để đưa ra kết quả gợi ý.

Trong pipeline tổng thể, Approach A đại diện cho nhóm phương pháp có chi phí tính toán thấp và khả năng triển khai nhanh. Tuy nhiên, do không mô hình hóa được ngữ cảnh dài và mối quan hệ ngữ nghĩa phức tạp giữa các thành phần trong văn bản, phương pháp này thường gặp hạn chế khi xử lý các bài báo có nội dung chuyên sâu hoặc đa chủ đề.

Do đó, Approach A được sử dụng làm mốc so sánh ban đầu nhằm đánh giá mức độ cải thiện của các phương pháp học sâu được trình bày trong các phần tiếp theo.

3.7.2 Vai trò của Approach B trong pipeline

Approach B đại diện cho nhóm phương pháp dựa trên Transformer, trong đó việc sử dụng các mô hình ngôn ngữ huấn luyện trước giúp cải thiện đáng kể chất lượng biểu diễn ngữ nghĩa so với các phương pháp embedding truyền thống. Pipeline của Approach B cho phép mô hình nắm bắt được ngữ cảnh toàn cục của văn bản thông qua cơ chế self-attention.

Trong pipeline hệ thống, Approach B đóng vai trò là bước chuyển tiếp giữa các phương pháp truyền thống và các phương pháp học tương tác nâng cao. Mặc dù cải thiện chất lượng biểu diễn, Approach B vẫn mã hóa bài báo và hội nghị một cách độc lập, do đó chưa khai thác trực tiếp mối quan hệ ngữ nghĩa giữa hai thực thể trong quá trình học biểu diễn.

Approach B được sử dụng như một baseline mạnh (strong baseline) để đánh giá lợi ích của việc tích hợp các cơ chế học tương tác trong các phương pháp tiếp theo.

3.7.3 Vai trò của Approach C trong pipeline

Approach C áp dụng khung học tương phản nhằm cải thiện chất lượng biểu diễn embedding thông qua việc học phân biệt các cặp bài báo–hội nghị phù hợp và không phù hợp. Pipeline hai giai đoạn của phương pháp này cho phép encoder học được các đặc trưng ngữ nghĩa giàu thông tin hơn so với các phương pháp chỉ dựa trên huấn luyện giám sát truyền thống.[13]

Trong pipeline tổng thể, Approach C đóng vai trò là phương pháp đại diện cho nhóm embedding-based contrastive learning, đồng thời là phương pháp so sánh trực tiếp với Sim-CPSR. Mặc dù đạt được cải thiện đáng kể so với Approach A và Approach B, phương pháp này vẫn duy trì giả định mã hóa độc lập giữa bài báo và hội nghị, dẫn đến việc tương tác chỉ xảy ra ở mức embedding toàn cục.

Do đó, Approach C được xem là bước tiền đề quan trọng cho việc phát triển phương pháp đề xuất, trong đó giả định mã hóa độc lập được thay thế bằng cách tiếp cận học tương tác trực tiếp.

3.7.4 Tổng hợp và định hướng phát triển

Thông qua phân tích pipeline của các phương pháp từ Approach A đến Approach C, có thể nhận thấy xu hướng phát triển rõ ràng từ các phương pháp biểu diễn đơn giản đến các phương pháp học biểu diễn nâng cao. Tuy nhiên, các phương pháp này vẫn chưa mô hình hóa trực tiếp tương tác giữa bài báo và hội nghị trong quá trình học biểu diễn.

Nhận xét này là cơ sở để đề xuất Approach D trong phần tiếp theo, với mục tiêu tích hợp cơ chế Cross-Attention nhằm học biểu diễn tương tác ở mức token-level, từ đó nâng cao hiệu quả của hệ thống gợi ý nộp bài.

3.8 Approach D – Phương pháp đề xuất dựa trên Cross-Attention

3.8.1 Động cơ và định hướng tiếp cận

Các phương pháp embedding-based trước đây, bao gồm cả các mô hình sử dụng học tương phản như SimCPSR, đều mã hóa nội dung bài báo và thông tin hội nghị hoặc tạp chí một cách độc lập trước khi thực hiện so khớp ở mức embedding. Trong các phương pháp này, mối quan hệ giữa bài báo và hội nghị được lượng hóa thông qua các độ đo tương đồng tĩnh, phổ biến nhất là cosine similarity trên không gian embedding.

Cách tiếp cận trên ngầm giả định rằng mức độ phù hợp giữa một bài báo và một hội nghị có thể được phản ánh đầy đủ thông qua một biểu diễn toàn cục. Tuy nhiên, trong thực tế, sự phù hợp này phụ thuộc mạnh vào *tương tác có điều kiện* giữa từng thành phần ngữ nghĩa của bài báo và phạm vi nghiên cứu của hội nghị. Một bài báo có thể phù hợp cao với một hội nghị ở một số chủ đề cụ thể, trong khi các phần nội dung khác lại ít hoặc không liên quan. Do đó, việc chỉ sử dụng embedding toàn cục có thể làm mất đi các tín hiệu tương tác quan trọng ở mức token.

Xuất phát từ nhận định trên, phương pháp đề xuất (Approach D) tiếp cận bài toán gợi ý nộp bài dưới góc nhìn *interaction-aware matching*, trong đó tương tác giữa bài báo và hội nghị được tích hợp trực tiếp vào quá trình học biểu diễn. Cụ thể, phương pháp này kế thừa khung học tương phản của SimCPSR nhằm duy trì khả năng học biểu diễn phân biệt, đồng thời mở rộng bằng cách thay thế cơ chế so khớp embedding tĩnh bằng cơ chế Cross-Attention để mô hình hóa tương tác token-level giữa hai chuỗi văn bản.[8, 12]

Nhờ việc tích hợp Cross-Attention, mô hình có khả năng tập trung vào các thành phần nội dung của bài báo phù hợp nhất với phạm vi nghiên cứu của từng hội nghị, thay vì chỉ dựa trên mức độ tương đồng toàn cục. Từ động cơ và định hướng tiếp cận này, các thành phần kiến trúc và cơ chế học tương tác của phương pháp đề xuất sẽ được trình bày chi tiết trong các phần tiếp theo.

3.8.2 Biểu diễn đầu vào và kiến trúc tổng thể

Trong phương pháp đề xuất, đầu vào của mô hình bao gồm hai chuỗi văn bản: (i) nội dung bài báo, được tạo bằng cách nối các trường Title, Abstract và Keywords; và (ii) nội dung Aims & Scope của hội nghị hoặc tạp chí.

Hai chuỗi văn bản này được token hóa độc lập và đưa vào các encoder dựa trên Transformer huấn luyện trước. Trong triển khai của luận văn, hai encoder có thể chia sẻ tham số nhằm giảm chi phí tính toán và tránh hiện tượng overfitting khi kích thước dữ liệu huấn luyện hạn chế.[25, 26]

Đầu ra của các encoder là các chuỗi embedding theo token, thay vì chỉ một vector toàn cục. Đây là điều kiện cần để áp dụng cơ chế Cross-Attention ở bước tiếp theo.

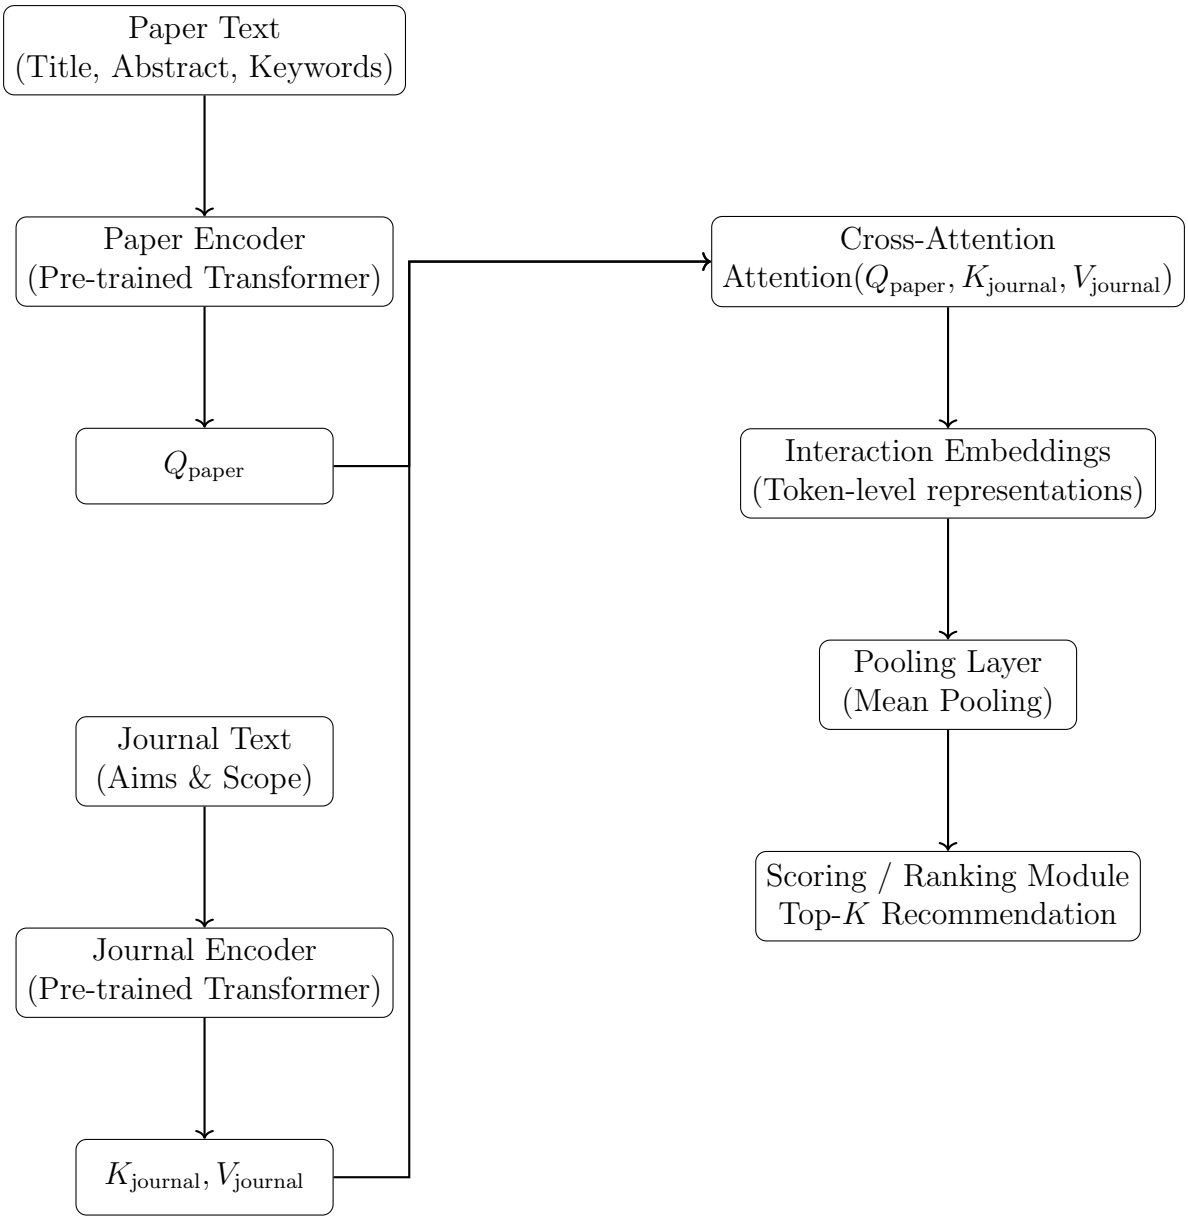

Hình 9: Kiến trúc tổng thể của phương pháp đề xuất dựa trên Cross-Attention (Approach D)

3.8.3 Cơ chế Cross-Attention trong pipeline

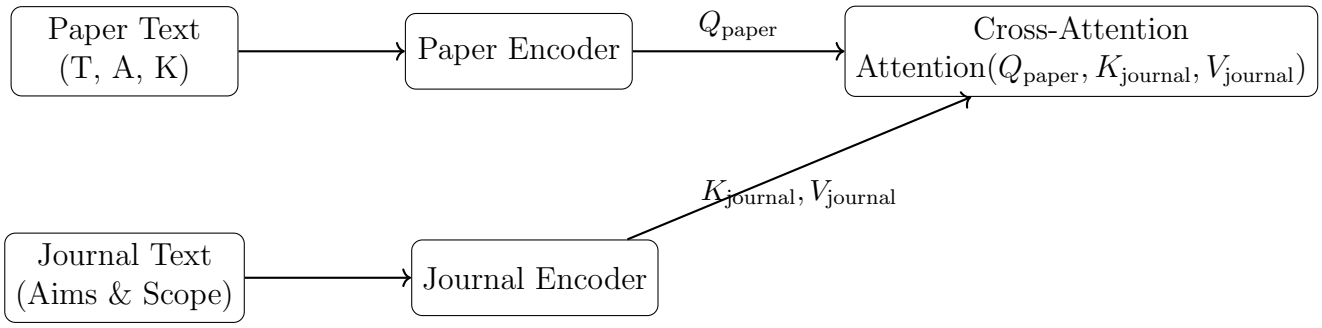

Hình 10: Chi tiết khối Cross-Attention trong phương pháp đề xuất (Approach D)

Hình 10 minh họa chi tiết cách cơ chế Cross-Attention được tích hợp trong pipeline của phương pháp đề xuất, trong đó biểu diễn của bài báo đóng vai trò Query, còn biểu diễn của

hội nghị đóng vai trò Key và Value.

Sau khi thu được biểu diễn token-level của bài báo và hội nghị, cơ chế Cross-Attention được áp dụng để mô hình hóa tương tác giữa hai chuỗi. Cụ thể, biểu diễn của bài báo đóng vai trò Query, trong khi biểu diễn của hội nghị đóng vai trò Key và Value.

Điểm tương tác giữa hai chuỗi văn bản được tính theo hàm score đã trình bày trong Chương 2, được nhắc lại ngắn gọn trong công thức (10). Thông qua hàm softmax, mô hình học được phân phối chú ý thể hiện mức độ liên quan giữa từng token của bài báo và các token trong Aims & Scope.[8, 9]

Đầu ra của Cross-Attention là một chuỗi embedding tương tác, trong đó mỗi token của bài báo đã được điều chỉnh theo ngữ cảnh của hội nghị. Biểu diễn này phản ánh mối quan hệ ngữ nghĩa có điều kiện, thay vì chỉ là sự tương đồng toàn cục như trong các phương pháp embedding-based.

3.8.4 Chiến lược pooling và biểu diễn tương tác

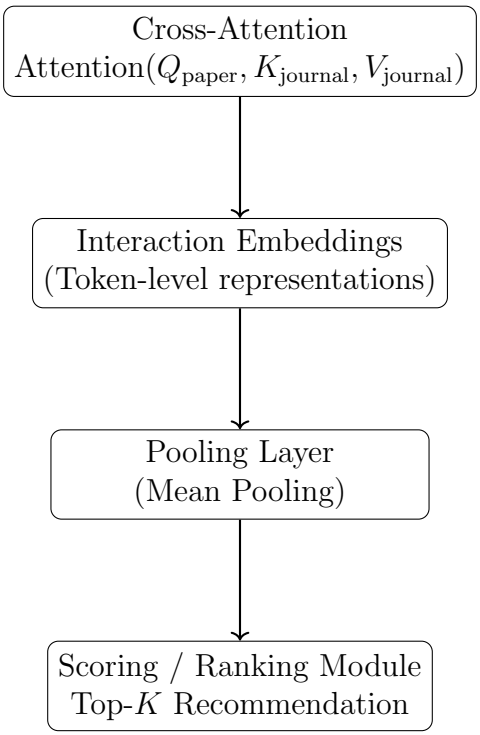

Hình 11: Pipeline suy luận của phương pháp đề xuất dựa trên Cross-Attention (Approach D)

Sau khối Cross-Attention, một chiến lược pooling được áp dụng để thu được biểu diễn cố định chiều cho cặp bài báo–hội nghị. Trong luận văn này, mean pooling trên chuỗi embedding tương tác được sử dụng do tính ổn định và khả năng tổng hợp thông tin từ toàn bộ chuỗi.

Biểu diễn pooling này được xem như một vector tương tác toàn cục, đóng vai trò đầu vào cho tầng phân loại hoặc xếp hạng ở bước tiếp theo. Việc tách riêng bước pooling giúp mô hình linh hoạt trong việc thay đổi chiến lược suy luận mà không ảnh hưởng đến khối Cross-Attention.

Hình 11 minh họa pipeline suy luận đầy đủ của phương pháp đề xuất. Sau khi thu được biểu diễn tương tác thông qua Cross-Attention, các embedding token-level được tổng hợp thành

biểu diễn cố định chiều bằng chiến lược pooling. Biểu diễn này được đưa vào hàm scoring để đánh giá mức độ phù hợp giữa bài báo và từng hội nghị, sau đó được sắp xếp nhằm lựa chọn danh sách Top-K hội nghị hoặc tạp chí phù hợp nhất.

3.8.5 Thuật toán huấn luyện

Thuật toán huấn luyện của phương pháp đề xuất được trình bày trong Thuật toán 3. Thuật toán này mô tả rõ luồng dữ liệu từ đầu vào văn bản đến bước tối ưu hàm mất mát.

Algorithm 3 Huấn luyện mô hình đề xuất dựa trên Cross-Attention

Require: Tập dữ liệu $D = \{(paper_i, journal_i)\}$
Ensure: Mô hình Cross-Attention đã huấn luyện
1: **for** each mini-batch $B \subset D$ **do**
2: Token hóa và encode bài báo $\rightarrow Q_{\text{paper}}$
3: Token hóa và encode Aims & Scope $\rightarrow K_{\text{journal}}, V_{\text{journal}}$
4: Áp dụng Cross-Attention theo công thức (10)
5: Thực hiện pooling để thu được biểu diễn tương tác
6: Cập nhật tham số mô hình thông qua tối ưu hàm mất mát
7: **end for**

3.8.6 Thuật toán suy luận và gợi ý Top-K

Trong giai đoạn suy luận, với một bài báo đầu vào, mô hình tính toán điểm phù hợp giữa bài báo và từng hội nghị hoặc tạp chí trong tập ứng viên. Các hội nghị được sắp xếp theo điểm số này và K hội nghị có điểm cao nhất được chọn làm kết quả gợi ý.

Algorithm 4 Suy luận và gợi ý Top-K hội nghị

Require: Bài báo p, tập hội nghị $\mathcal{J}$
Ensure: Danh sách Top-K hội nghị
1: **for** each $j \in \mathcal{J}$ **do**
2: Encode p và j
3: Áp dụng Cross-Attention và pooling
4: Tính điểm phù hợp
5: **end for**
6: Sắp xếp và chọn Top-K

3.8.7 Phân tích độ phức tạp tính toán

Giả sử độ dài chuỗi token của bài báo và hội nghị lần lượt là L_p và L_j, và chiều embedding là d. Độ phức tạp tính toán của khối Cross-Attention xấp xỉ $O(L_p \cdot L_j \cdot d)$. Mặc dù chi phí này cao hơn so với các phương pháp embedding-based, nhưng đổi lại mô hình có khả năng học tương tác ngữ nghĩa chi tiết hơn giữa hai chuỗi văn bản.

Trong thực nghiệm, chi phí tính toán có thể được kiểm soát bằng cách giới hạn độ dài chuỗi đầu vào hoặc chia sẻ tham số encoder giữa hai nhánh.

3.8.8 Thảo luận thiết kế và so sánh với Approach C

So với Approach C, phương pháp đề xuất khác biệt ở điểm cốt lõi là vị trí tích hợp tương tác. Trong khi Approach C chỉ học biểu diễn tốt hơn ở mức embedding, Approach D cho phép

tương tác xảy ra ngay trong quá trình biểu diễn, giúp mô hình tập trung vào các phần nội dung phù hợp nhất của bài báo đối với từng hội nghị cụ thể.[13]

Thiết kế này giúp giảm sự phụ thuộc vào các độ đo tương đồng tĩnh và mở ra khả năng mở rộng mô hình cho các kịch bản gợi ý phức tạp hơn trong tương lai.

3.8.9 Tổng kết Approach D

Approach D là phương pháp đề xuất của luận văn, tiếp cận bài toán gợi ý nộp bài ở mức interaction-aware thông qua Cross-Attention. Với việc mô hình hóa trực tiếp tương tác token-level giữa bài báo và hội nghị, phương pháp này khắc phục các hạn chế của các phương pháp embedding-based và là nền tảng cho các đánh giá thực nghiệm trong chương tiếp theo.

3.9 Cấu hình huấn luyện và thiết lập thực nghiệm

Phần này trình bày cấu hình huấn luyện và thiết lập thực nghiệm được áp dụng cho tất cả các phương pháp đã trình bày trong chương này, bao gồm các phương pháp cơ sở, các mô hình dựa trên Transformer, phương pháp học tương phản và phương pháp đề xuất dựa trên Cross-Attention. Việc sử dụng thiết lập huấn luyện thống nhất giúp đảm bảo tính công bằng trong so sánh và làm rõ tác động của kiến trúc mô hình thay vì sự khác nhau trong siêu tham số.

Đối với các phương pháp dựa trên Transformer, encoder được khởi tạo từ các mô hình ngôn ngữ huấn luyện trước và được fine-tune trong quá trình huấn luyện. Trong trường hợp dữ liệu huấn luyện có kích thước hạn chế, một số tầng đầu của encoder có thể được cố định tham số nhằm giảm nguy cơ overfitting và chi phí tính toán, đồng thời vẫn giữ được các đặc trưng ngữ nghĩa đã học từ giai đoạn huấn luyện trước.

Các tham số huấn luyện chính bao gồm batch size, learning rate, số epoch và optimizer. Trong các thí nghiệm, optimizer Adam được sử dụng do khả năng hội tụ ổn định trong các mô hình học sâu. Learning rate được lựa chọn ở mức nhỏ nhằm đảm bảo quá trình fine-tune diễn ra ổn định và không làm mất các đặc trưng ngôn ngữ quan trọng.

Đối với các phương pháp có sử dụng học tương phản, nhiệt độ τ trong hàm mất mát tương phản được giữ cố định trong toàn bộ quá trình huấn luyện. Việc giữ nguyên tham số này giúp đảm bảo rằng sự khác biệt về kết quả giữa các phương pháp phản ánh đúng tác động của cơ chế tương tác và chiến lược biểu diễn, thay vì xuất phát từ việc tinh chỉnh siêu tham số.

Tất cả các mô hình được huấn luyện trong cùng một số epoch và được đánh giá trên cùng tập kiểm tra. Cách thiết lập này đảm bảo rằng các kết quả được trình bày trong Chương 4 phản ánh sự khác biệt thực chất giữa các phương pháp, thay vì do sự khác nhau trong cấu hình huấn luyện.

3.10 Thảo luận lựa chọn thiết kế

Phần này thảo luận các lựa chọn thiết kế chính trong quá trình xây dựng pipeline và mô hình đề xuất, đồng thời phân tích tác động của các lựa chọn này đối với hiệu quả của hệ thống gợi ý nộp bài. Các thảo luận được trình bày theo hướng phân tích định tính, tương tự như các nghiên cứu liên quan trong lĩnh vực gợi ý học thuật.

3.10.1 Vị trí tích hợp Cross-Attention

Trong phương pháp đề xuất, cơ chế Cross-Attention được đặt sau các encoder dựa trên Transformer, thay vì được tích hợp trực tiếp vào đầu vào thô. Lựa chọn này nhằm đảm bảo rằng mỗi token trong chuỗi văn bản đã được mã hóa với ngữ cảnh toàn cục trước khi tham gia vào quá trình tương tác.

Việc đặt Cross-Attention sau encoder giúp mô hình tận dụng được các đặc trưng ngữ nghĩa giàu thông tin đã học từ các mô hình ngôn ngữ huấn luyện trước, đồng thời cho phép cơ chế tương tác tập trung vào việc mô hình hóa mối quan hệ có điều kiện giữa bài báo và hội nghị. Nếu Cross-Attention được áp dụng quá sớm, mô hình có thể gặp khó khăn trong việc học các tương tác có ý nghĩa do biểu diễn đầu vào còn mang nhiều nhiễu.

3.10.2 So sánh Cross-Attention và so khớp embedding tĩnh

Các phương pháp embedding-based như Approach A và Approach C thực hiện so khớp giữa bài báo và hội nghị thông qua các độ đo tương đồng tĩnh trên không gian embedding. Cách tiếp cận này giả định rằng mối quan hệ giữa hai thực thể có thể được phản ánh đầy đủ thông qua một biểu diễn toàn cục.

Ngược lại, phương pháp đề xuất sử dụng Cross-Attention để mô hình hóa tương tác ở mức token, cho phép mô hình tập trung vào các phần nội dung cụ thể của bài báo phù hợp với phạm vi nghiên cứu của từng hội nghị. Sự khác biệt này đặc biệt quan trọng trong các trường hợp bài báo có nội dung đa chủ đề hoặc hội nghị có phạm vi nghiên cứu hẹp.

3.10.3 Ảnh hưởng của chiến lược pooling

Sau khối Cross-Attention, chiến lược pooling được sử dụng để tổng hợp thông tin từ chuỗi embedding tương tác thành một biểu diễn cố định chiều. Trong luận văn này, mean pooling được lựa chọn do khả năng tổng hợp thông tin từ toàn bộ chuỗi và tính ổn định trong huấn luyện.

Mặc dù các chiến lược pooling khác như max pooling hoặc sử dụng token đặc biệt cũng có thể được áp dụng, mean pooling giúp giảm sự phụ thuộc vào vị trí cụ thể của token và phù hợp với mục tiêu học biểu diễn tương tác toàn cục giữa bài báo và hội nghị.

3.10.4 Khả năng mở rộng và hạn chế

Phương pháp đề xuất dựa trên Cross-Attention có độ phức tạp tính toán cao hơn so với các phương pháp embedding-based, đặc biệt khi độ dài chuỗi đầu vào tăng. Tuy nhiên, chi phí này có thể được kiểm soát thông qua việc giới hạn độ dài chuỗi hoặc sử dụng các chiến lược chia sẻ tham số giữa các encoder.

Mặc dù còn tồn tại các hạn chế về chi phí tính toán, phương pháp đề xuất mở ra khả năng mở rộng cho các kịch bản gợi ý phức tạp hơn trong tương lai, chẳng hạn như gợi ý đa hội nghị hoặc mô hình hóa tương tác nhiều chiều giữa các thực thể học thuật.

3.10.5 Tổng kết thảo luận thiết kế

Các lựa chọn thiết kế trong luận văn được đưa ra dựa trên sự cân nhắc giữa hiệu quả biểu diễn và chi phí tính toán, đồng thời phù hợp với đặc thù của bài toán gợi ý nộp bài báo khoa học. Thông qua việc tích hợp cơ chế Cross-Attention, phương pháp đề xuất khắc phục các hạn

chế của các phương pháp embedding-based và tạo nền tảng cho các đánh giá thực nghiệm trong chương tiếp theo.

3.11 Tổng kết chương

Chương này đã trình bày chi tiết pipeline và thuật toán của bốn cách tiếp cận. Phương pháp đề xuất dựa trên Cross-Attention tiếp cận bài toán ở mức interaction-aware và là nền tảng cho phần đánh giá thực nghiệm trong chương tiếp theo.

4 Thực nghiệm và đánh giá

4.1 Mô tả tập dữ liệu

Trong báo cáo này, tác giả sử dụng cùng tập dữ liệu và quy trình thu thập dữ liệu được đề xuất trong công trình SimCPSR [13], nhằm đảm bảo tính công bằng và khả năng so sánh trực tiếp giữa các phương pháp.

4.1.1 Nguồn dữ liệu

Tập dữ liệu được thu thập từ nhà xuất bản *Springer*, bao gồm các bài báo khoa học đã được chấp nhận tại các hội nghị và tạp chí thuộc nhiều lĩnh vực khác nhau. Mỗi mẫu dữ liệu tương ứng với một bài báo và một hội nghị hoặc tạp chí mà bài báo đó được nộp và chấp nhận.

Dữ liệu được xây dựng phục vụ trực tiếp cho bài toán gợi ý nộp bài báo khoa học (Paper Submission Recommendation), trong đó mục tiêu là dự đoán hoặc gợi ý hội nghị/tạp chí phù hợp cho một bài báo mới dựa trên nội dung học thuật của bài báo và phạm vi nghiên cứu của địa điểm nộp bài.

4.1.2 Quy mô và cách chia dữ liệu

Tổng cộng, tập dữ liệu bao gồm **414,512** bài báo khoa học. Trong đó:

- **331,464** mẫu được sử dụng cho quá trình huấn luyện (training set),
- **33,146** mẫu được sử dụng cho quá trình kiểm chứng (validation set),
- **83,048** mẫu được sử dụng cho quá trình kiểm thử (testing set).

Tập dữ liệu được chia theo tỷ lệ **9:1** giữa huấn luyện và kiểm chứng, trong khi tập kiểm thử được giữ riêng biệt và không tham gia vào quá trình huấn luyện hay tinh chỉnh mô hình. Cách chia này tuân theo thiết lập thực nghiệm trong SimCPSR [13] và được áp dụng nhất quán cho tất cả các phương pháp trong báo cáo.

4.1.3 Cấu trúc dữ liệu bài báo

Mỗi bài báo khoa học trong tập dữ liệu được biểu diễn thông qua ba trường văn bản chính:

- **Title**: tiêu đề bài báo,
- **Abstract**: phần tóm tắt nội dung nghiên cứu,
- **Keywords**: danh sách từ khóa do tác giả cung cấp.

Ba trường này phản ánh các mức độ thông tin khác nhau của bài báo, từ tóm lược ngắn gọn (Title), mô tả chi tiết (Abstract) đến các khái niệm trọng tâm (Keywords). Trong các thí nghiệm, các trường văn bản này được kết hợp thành nhiều tổ hợp đặc trưng khác nhau (T, A, K, TA, AK, TK, TAK, TAKS) nhằm đánh giá mức độ đóng góp của từng nguồn thông tin, tương tự như thiết lập trong SimCPSR [13].

Bảng 2 minh họa một số ví dụ về ba trường văn bản của bài báo sau khi đã được tiền xử lý.

Bảng 2: Một số ví dụ về Title, Abstract và Keywords trong tập dữ liệu đã được tiền xử lý

Title	**Abstract**	**Keywords**
amperometric photosensor based acridine orange tio	authors novel sensor chlorogenic acid cga detection quantification food samples photosensor based composite titanium dioxide tio acridine orange ao synergism ao tio revealed visible led light irradiation high photocurrents cga compared component composite material detection limit ...	photosensor tio acridine orange chlorogenic acid
governance options science policy interfaces biodiversity ecosystem services comparing network versus platform approach	science policy interfaces spis expected linear model scientific policy advice creating spaces exchange dialogue policy knowledge given environmental issues require inter transdisciplinary approaches spis account variety knowledge types views interests scientists policymakers decision makers ...	science policy interface european environmental policy research networking biodiversity ecosystem services acid

4.1.4 Cấu trúc dữ liệu hội nghị và tạp chí

Thông tin của hội nghị hoặc tạp chí được biểu diễn thông qua trường **Aims & Scope**, mô tả phạm vi nghiên cứu, các chủ đề quan tâm và định hướng học thuật của địa điểm nộp bài.

Trường Aims & Scope đóng vai trò đặc biệt quan trọng trong bài toán gợi ý nộp bài, vì nó thể hiện rõ tiêu chí tiếp nhận bài báo của từng hội nghị hoặc tạp chí. Trong tập dữ liệu, thông tin Aims & Scope cũng được thu thập từ trang web chính thức của nhà xuất bản Springer, đảm bảo tính đồng nhất và độ tin cậy của dữ liệu [13].

Bảng 3 trình bày một số ví dụ về nội dung Aims & Scope tương ứng với các tạp chí trong tập dữ liệu.

Bảng 3: Một vài ví dụ về Aims and Scope thuộc các tạp chí có trong tập dữ liệu

Aims and Scope
food analytical methods publishes original articles review articles notes novel state art analytical methods issues solved significant improvements interesting applications existing methods include analytical technology methodology food microbial contaminants food chemistry toxicology food quality food authenticity...
founded biodiversity conservation international journal publishes articles aspects biological diversity conservation sustainable use multidisciplinary covers living organisms kinds habitat...

4.2 Các kết quả thực nghiệm trước đó (từ simCPSR)

4.2.1 Độ đo đánh giá

Trong bài toán gợi ý hội nghị/tạp chí, tác giả công trình SimCPSR sử dụng độ đo *Accuracy@K* (với $K \in \{1, 3, 5, 10\}$) để đánh giá hiệu quả của các phương pháp đề xuất.

Độ đo Accuracy@K được định nghĩa như sau:

$$\text{Accuracy@}K = \frac{1}{|X|} \sum_{i=1}^{|X|} \mathbb{I}\big(y_i \in \text{Top-}K(x_i)\big), \tag{11}$$

trong đó:

- x_i là bài báo thứ i trong tập kiểm tra;
- y_i là nhãn hội nghị/tạp chí đúng (ground truth) của bài báo x_i;
- Top-$K(x_i)$ là danh sách K hội nghị/tạp chí được mô hình đề xuất có điểm số cao nhất cho x_i;
- $\mathbb{I}(\cdot)$ là hàm chỉ thị, nhận giá trị 1 nếu điều kiện bên trong đúng, và 0 trong trường hợp ngược lại.

Accuracy@K phản ánh tỷ lệ các bài báo mà hội nghị/tạp chí đúng xuất hiện trong danh sách K đề xuất hàng đầu của mô hình.

4.2.2 Kết quả thực nghiệm

Bảng 4: Accuracy@K của các tập đặc trưng trong các cách tiếp cận Approach A, Approach B và Approach C từ simCPSR

Approach	Metric	T	TS	K	KS	A	AS	TK	TKS	TA	TAS	AK	AKS	TAK	TAKS
Approach A	Top1	0.3542	0.4015	0.3933	0.4284	0.4691	0.4770	0.4157	0.4475	0.4644	0.4828	0.4791	0.4951	0.4852	**0.5002**
	Top3	0.6634	0.6991	0.7008	0.7256	0.7661	0.7662	0.7315	0.7490	0.7613	0.7754	0.7730	0.7830	0.7856	**0.7889**
	Top5	0.7561	0.7971	0.7919	0.8189	0.8482	0.8488	0.8232	0.8302	0.8448	0.8536	0.8530	0.8602	0.8621	**0.8627**
	Top10	0.8532	0.8951	0.8852	0.9075	0.9253	0.9258	0.9084	0.9127	0.9233	0.9276	0.9273	0.9304	0.9333	**0.9323**
Approach B	Top1	0.3708	0.3705	0.3993	0.4004	0.5034	0.5017	0.4351	0.4365	0.5066	0.5100	0.5163	0.5089	0.5149	**0.5164**
	Top3	0.6516	0.6456	0.6876	0.6864	0.7957	0.7947	0.7378	0.7384	0.8025	0.8046	0.8089	0.8006	0.8078	**0.8061**
	Top5	0.7500	0.7423	0.7811	0.7815	0.8737	0.8741	0.8272	0.8294	0.8797	0.8821	0.8861	0.8787	0.8858	**0.8834**
	Top10	0.8520	0.8481	0.8786	0.8796	0.9431	0.9431	0.9136	0.9154	0.9475	0.9473	0.9501	0.9464	0.9506	**0.9486**
Approach C	Top1	0.3770	0.3786	0.4083	0.4126	0.5085	0.5139	0.4439	0.4493	0.5110	0.5171	0.5251	0.5288	0.5269	**0.5310**
	Top3	0.6652	0.6656	0.7101	0.7100	0.8039	0.8055	0.7500	0.7536	0.8070	0.8111	0.8197	0.8229	0.8229	**0.8264**
	Top5	0.7599	0.7594	0.7983	0.7970	0.8806	0.8809	0.8381	0.8400	0.8827	0.8856	0.8912	0.8930	0.8940	**0.8963**
	Top10	0.8586	0.8570	0.8884	0.8883	0.9460	0.9472	0.9181	0.9196	0.9471	0.9486	0.9526	0.9538	0.9531	**0.9544**

Dựa trên kết quả thực nghiệm được trình bày trong Bảng 4, có thể rút ra một số nhận xét tổng quát về hiệu quả của các cách tiếp cận và các tập đặc trưng được sử dụng trong bài toán gợi ý hội nghị/tạp chí khoa học.

Trước hết, xét về mặt tổng quan, hiệu năng của các mô hình tăng dần theo thứ tự Approach A, Approach B và Approach C trên hầu hết các độ đo Accuracy@K. Approach A, sử dụng các biểu diễn từ vựng tĩnh, đạt kết quả thấp nhất, đặc biệt ở Top-1 Accuracy. Điều này cho thấy các phương pháp dựa trên embedding truyền thống gặp hạn chế trong việc nắm bắt ngữ nghĩa học thuật phức tạp của bài báo khoa học. Khi chuyển sang Approach B, với việc sử dụng mô

hình ngôn ngữ ngữ cảnh dựa trên Transformer, hiệu quả gợi ý được cải thiện rõ rệt ở tất cả các mức Top-K, khẳng định ưu thế của biểu diễn ngữ cảnh trong các bài toán khớp văn bản chuyên ngành.

Đối với Approach C, việc sử dụng encoder đã được tinh chỉnh ở giai đoạn tiền huấn luyện bằng học tương phản tiếp tục mang lại sự cải thiện ổn định so với Approach B. Đặc biệt, mức cải thiện thể hiện rõ ràng nhất ở Top-1 Accuracy, cho thấy học tương phản giúp mô hình học được không gian biểu diễn có tính phân biệt cao hơn giữa các hội nghị/tạp chí khác nhau. Kết quả này phù hợp với mục tiêu của các phương pháp dựa trên contrastive learning như SimCPSR, trong đó việc tối ưu hóa quan hệ tương đối giữa các biểu diễn đóng vai trò quan trọng trong bài toán gợi ý.

Xét về ảnh hưởng của các tập đặc trưng, các cấu hình chỉ sử dụng thông tin đơn lẻ từ bài báo (như Title, Abstract hoặc Keywords) cho kết quả hạn chế trong cả ba cách tiếp cận. Khi bổ sung thông tin Aims & Scope của hội nghị, hiệu năng mô hình được cải thiện đáng kể, cho thấy vai trò quan trọng của thông tin mô tả phạm vi nghiên cứu của hội nghị trong việc khớp bài báo với nơi công bố phù hợp. Đặc biệt, các tập đặc trưng kết hợp đầy đủ thông tin từ bài báo và hội nghị (TA, TAS, AK, AKS, TAK và TAKS) luôn đạt kết quả cao nhất.

Trong cả ba cách tiếp cận, cấu hình TAKS cho thấy hiệu năng vượt trội so với các cấu hình còn lại. Kết quả này nhấn mạnh rằng việc kết hợp đồng thời Title, Abstract, Keywords của bài báo cùng với Aims & Scope của hội nghị giúp mô hình khai thác được đầy đủ cả ngữ cảnh nội dung và phạm vi công bố, từ đó nâng cao độ chính xác của danh sách gợi ý. Đặc biệt, trong Approach C, cấu hình TAKS đạt giá trị Top-1 Accuracy cao nhất trong toàn bộ các thí nghiệm, đồng thời duy trì hiệu năng ổn định ở các mức Top-K cao hơn.

Tóm lại, các kết quả thực nghiệm cho thấy ba yếu tố đóng vai trò then chốt trong bài toán gợi ý hội nghị/tạp chí khoa học, bao gồm: (i) sử dụng mô hình ngôn ngữ ngữ cảnh mạnh mẽ, (ii) khai thác thông tin Aims & Scope của hội nghị, và (iii) tinh chỉnh encoder bằng học tương phản ở giai đoạn tiền huấn luyện. Sự kết hợp của các yếu tố này, thể hiện rõ nhất trong Approach C với cấu hình TAKS, mang lại hiệu quả gợi ý cao nhất và là hướng tiếp cận phù hợp cho các hệ thống gợi ý công bố khoa học trong thực tế.

4.3 Thiết lập thực nghiệm

4.3.1 Phạm vi dữ liệu

Trong quá trình thực nghiệm, nghiên cứu này được triển khai trong điều kiện tài nguyên phần cứng hạn chế, đặc biệt là về bộ nhớ và năng lực tính toán của GPU. Các mô hình trong Approach A, Approach B và Approach C chủ yếu dựa trên kiến trúc Transformer dạng encoder, cho phép xử lý hiệu quả trên tập dữ liệu tương đối lớn. Tuy nhiên, đối với mô hình re-ranking dựa trên Cross-Attention (Approach D), chi phí tính toán tăng lên đáng kể do mô hình phải thực hiện tương tác ở mức token giữa bài báo và từng hội nghị/tạp chí ứng viên.

Cụ thể, trong Approach D, mỗi bài báo cần được so khớp lần lượt với từng hội nghị/tạp chí trong tập ứng viên, dẫn đến độ phức tạp thời gian xấp xỉ $\mathcal{O}(M \cdot L_p \cdot L_j)$, trong đó M là số lượng hội nghị/tạp chí ứng viên, L_p và L_j lần lượt là độ dài chuỗi token của bài báo và phần Aims & Scope của hội nghị. Do đó, việc áp dụng mô hình Cross-Attention trực tiếp trên toàn bộ tập hội nghị là không khả thi trong điều kiện phần cứng hiện có.

Để đảm bảo tính khả thi của thí nghiệm, Approach D được sử dụng theo hướng re-ranking, trong đó mô hình chỉ thực hiện xếp hạng lại trên tập ứng viên Top-M được truy hồi từ giai đoạn trước (Approach C). Trong các thí nghiệm, giá trị M được cố định lần lượt ở các mức M = (10, 20, 30, 50), giúp cân bằng giữa hiệu quả re-ranking và chi phí tính toán. Cách tiếp cận này cũng phù hợp với thiết kế phổ biến của các hệ thống hai giai đoạn (retrieval–re-ranking) trong các bài toán truy hồi và gợi ý.

Bên cạnh đó, do giới hạn về thời gian huấn luyện và bộ nhớ GPU, các tập dữ liệu huấn luyện và kiểm tra cho các thí nghiệm được xây dựng dưới dạng các tập con của tập dữ liệu gốc. Cụ thể, các tập *sub_train* và *sub_test* được tạo bằng cách lấy ngẫu nhiên 1000 mẫu từ tập huấn luyện và tập kiểm tra ban đầu. Việc lấy mẫu ngẫu nhiên giúp đảm bảo các tập con vẫn giữ được phân bố tương đối đa dạng của dữ liệu gốc, đồng thời cho phép tiến hành so sánh công bằng giữa các cách tiếp cận trong cùng một điều kiện thực nghiệm.

Cần lưu ý rằng việc sử dụng tập dữ liệu con có thể ảnh hưởng đến giá trị tuyệt đối của các độ đo đánh giá. Tuy nhiên, trong phạm vi nghiên cứu này, mục tiêu chính là so sánh tương đối hiệu quả giữa các cách tiếp cận khác nhau. Do đó, thiết lập thực nghiệm trên các tập con với kích thước cố định vẫn phản ánh được xu hướng hiệu năng và vai trò của từng thành phần trong hệ thống gợi ý được đề xuất.

4.3.2 Độ đo đánh giá

Độ đo Accuracy@K được áp dụng để đánh giá các phương pháp đề xuất trên toàn bộ không gian hội nghị/tạp chí, bao gồm các mô hình phân loại và truy hồi dựa trên biểu diễn embedding (Approach A, B và C). Trong các phương pháp này, mỗi bài báo đều được ánh xạ tới một danh sách đề xuất Top-K trên toàn bộ tập hội nghị, do đó Accuracy@K là độ đo phù hợp và có ý nghĩa.

Đối với mô hình re-ranking dựa trên Cross-Attention (Approach D), mô hình chỉ thực hiện xếp hạng lại trên tập ứng viên Top-M được truy hồi từ trước. Do đó, độ đo Accuracy@K toàn cục không còn phù hợp trong trường hợp này. Thay vào đó, các độ đo xếp hạng như Mean Rank và Hit@K trong tập Top-M được sử dụng để đánh giá mức cải thiện thứ hạng của hội nghị/tạp chí đúng.

Mean Rank: Mean Rank đo lường vị trí trung bình của hội nghị/tạp chí đúng trong danh sách xếp hạng sau khi re-ranking. Độ đo này được định nghĩa như sau:

$$\text{MeanRank} = \frac{1}{|X'|} \sum_{i=1}^{|X'|} \text{rank}(y_i), \tag{12}$$

trong đó:

- X' là tập các bài báo mà hội nghị/tạp chí đúng xuất hiện trong tập ứng viên Top-M được truy hồi;
- y_i là hội nghị/tạp chí đúng của bài báo x_i;
- $\text{rank}(y_i)$ là vị trí xếp hạng của y_i trong danh sách re-ranking (vị trí càng nhỏ càng tốt).

Giá trị Mean Rank càng thấp cho thấy mô hình re-ranking càng hiệu quả trong việc đưa hội nghị/tạp chí đúng lên các vị trí cao hơn trong danh sách đề xuất.

Hit@K trong Top-M: Hit@K đánh giá tỷ lệ các bài báo mà hội nghị/tạp chí đúng xuất hiện trong K vị trí đầu tiên của danh sách re-ranking. Độ đo này được xác định bởi:

$$\text{Hit@}K = \frac{1}{|X'|} \sum_{i=1}^{|X'|} \mathbb{I}\big(\text{rank}(y_i) \leq K\big), \tag{13}$$

Trong đó: $\mathbb{I}(\cdot)$ là hàm chỉ thị, nhận giá trị 1 nếu điều kiện bên trong đúng và 0 trong trường hợp ngược lại.

Độ đo Hit@K phản ánh khả năng của mô hình re-ranking trong việc đưa hội nghị/tạp chí đúng vào nhóm K đề xuất hàng đầu, trong bối cảnh tập ứng viên đã được giới hạn bởi giai đoạn truy hồi trước đó.

Cần lưu ý rằng các độ đo Mean Rank và Hit@K trong Top-M chỉ được tính trên tập X', tức là các bài báo mà hội nghị/tạp chí đúng đã xuất hiện trong danh sách ứng viên Top-M. Đây là cách đánh giá phổ biến đối với các mô hình re-ranking, do mô hình không có khả năng cải thiện các trường hợp mà hội nghị đúng không được truy hồi ở giai đoạn trước.

4.4 Kết quả thực nghiệm và phân tích

Phần này trình bày kết quả so sánh giữa phương pháp Embedding-based Contrastive Learning (Approach C – TAKS) và phương pháp đề xuất dựa trên Cross-Attention (Approach D – TAKS + D).

Các thí nghiệm được thực hiện với nhiều giá trị M khác nhau. Tại mỗi cấu hình, hệ thống được đánh giá theo các chỉ số:

- **Mean Rank (MR)**: Trung bình thứ hạng của hội nghị/tạp chí đúng trong danh sách xếp hạng. Giá trị càng nhỏ thì mô hình càng tốt.
- **Hit@1**: Tỷ lệ mẫu mà hội nghị đúng xuất hiện ở vị trí đầu tiên trong danh sách xếp hạng.
- **Hit@3**: Tỷ lệ mẫu mà hội nghị đúng nằm trong Top-3 kết quả được đề xuất.
- **Hit@5**: Tỷ lệ mẫu mà hội nghị đúng nằm trong Top-5 kết quả.
- **Hit@10**: Tỷ lệ mẫu mà hội nghị đúng nằm trong Top-10 kết quả.

4.4.1 Kết quả với M = 10

Bảng 5: So sánh Approach C và Approach D với $M = 10$

Metric	TAKS	TAKS + D
Mean Rank	6.75	**5.32**
Hit@1	**0.0714**	0.0357
Hit@3	0.1429	**0.2857**
Hit@5	0.2143	**0.5714**
Hit@10	1.0000	1.0000

Nhận xét: Khi $M = 10$, phương pháp đề xuất (TAKS + D) giúp cải thiện đáng kể Mean Rank và đặc biệt là Hit@3 và Hit@5. Điều này cho thấy Cross-Attention giúp nâng cao khả năng xếp hạng chính xác trong Top-K. Tuy nhiên, Hit@1 chưa được cải thiện.

4.4.2 Kết quả với M = 20

Bảng 6: So sánh Approach C và Approach D với $M = 20$

Metric	TAKS	TAKS + D
Mean Rank	11.88	**10.46**
Hit@1	**0.0357**	0.0179
Hit@3	0.0714	**0.1071**
Hit@5	0.1071	**0.1607**
Hit@10	0.5000	**0.6071**

Nhận xét: Với $M = 20$, Approach D tiếp tục cải thiện Mean Rank và các chỉ số Hit@3, Hit@5 và Hit@10. Điều này cho thấy cơ chế tương tác token-level giúp mô hình duy trì hiệu quả ngay cả khi không gian ứng viên tăng lên.

4.4.3 Kết quả với M = 30

Bảng 7: So sánh Approach C và Approach D với $M = 30$

Metric	TAKS	TAKS + D
Mean Rank	16.89	**15.20**
Hit@1	**0.0222**	0.0111
Hit@3	0.0444	**0.0667**
Hit@5	0.0667	**0.1111**
Hit@10	0.3111	**0.3222**

Nhận xét: Khi số lượng ứng viên tăng lên $M = 30$, Approach D vẫn giữ được xu hướng cải thiện Mean Rank và các chỉ số Hit@K (ngoại trừ Hit@1). Mức cải thiện tuy không lớn nhưng ổn định.

4.4.4 Kết quả với M = 50

Bảng 8: So sánh Approach C và Approach D với $M = 50$

Metric	TAKS	TAKS + D
Mean Rank	26.47	**25.10**
Hit@1	**0.0128**	0.0064
Hit@3	0.0256	**0.0321**
Hit@5	0.0385	**0.0641**
Hit@10	**0.1795**	0.1410

Nhận xét: Với $M = 50$, Approach D tiếp tục giảm Mean Rank và cải thiện Hit@3, Hit@5. Tuy nhiên, Hit@1 và Hit@10 chưa vượt qua Approach C, cho thấy khi không gian tìm kiếm lớn, lợi ích của Cross-Attention có xu hướng giảm ở vị trí cao nhất.

4.4.5 Biểu đồ so sánh

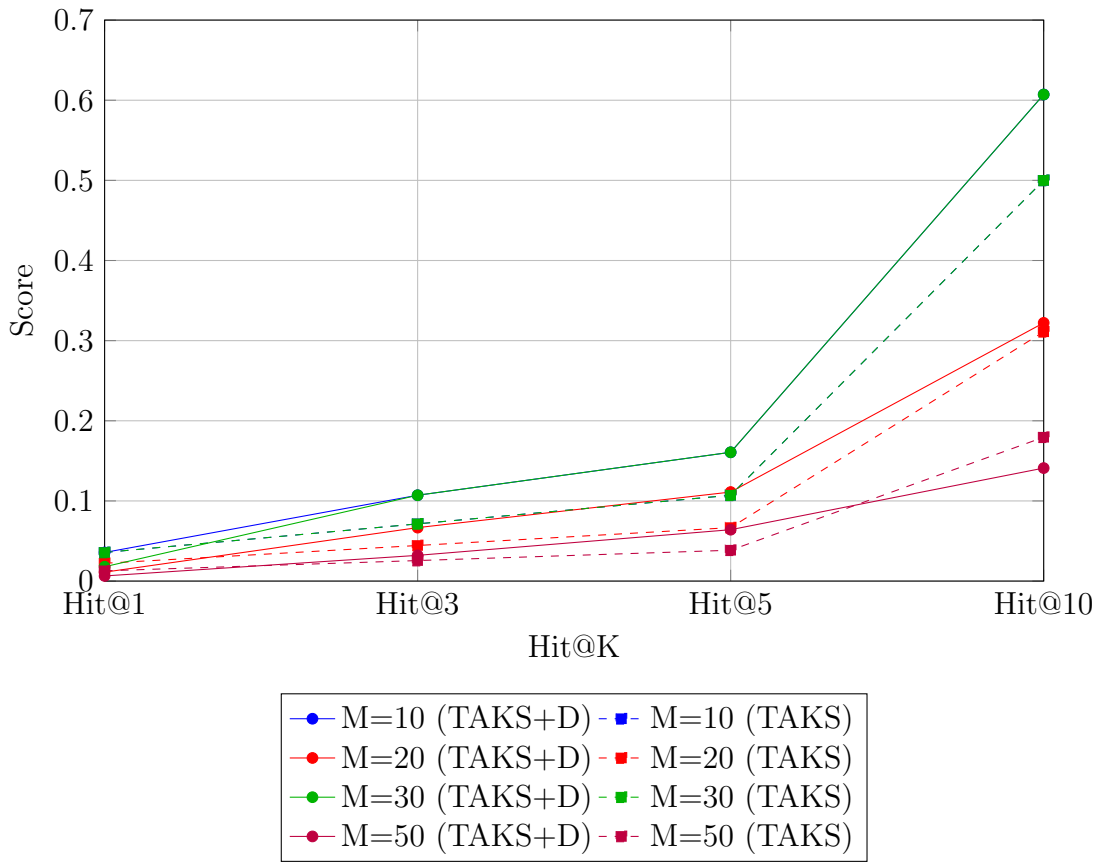

Hình 12: So sánh Hit@K giữa Approach C (TAKS) và Approach D (TAKS+D) theo các giá trị M khác nhau

Có thể quan sát thấy rằng:

- Đối với các giá trị M nhỏ (M=10 và M=30), Approach D cải thiện rõ rệt các chỉ số Hit@3 và Hit@5, đồng thời giảm đáng kể Mean Rank. Điều này cho thấy cơ chế Cross-Attention giúp điều chỉnh lại thứ hạng của hội nghị đúng theo hướng ưu tiên các vị trí cao hơn trong danh sách.
- Khi M tăng lên (M=20 và M=50), mức cải thiện không còn quá lớn, đặc biệt ở Hit@1. Tuy nhiên, Mean Rank vẫn tiếp tục giảm và các chỉ số Hit@K trung bình (như Hit@3 và Hit@5) duy trì xu hướng tích cực. Điều này cho thấy Cross-Attention vẫn giữ được khả năng tái sắp xếp ứng viên ngay cả khi không gian tìm kiếm mở rộng.
- Việc Mean Rank giảm nhất quán ở tất cả các cấu hình M phản ánh rằng mô hình re-ranking hoạt động ổn định, ngay cả khi mức cải thiện tại vị trí cao nhất (Top-1) chưa thực sự rõ rệt.

Nhìn chung, kết quả thực nghiệm cho thấy Cross-Attention đóng vai trò tinh chỉnh thứ hạng trong tập ứng viên đã được truy hồi, thay vì thay đổi đột biến ở vị trí đầu tiên. Điều này phù hợp với bản chất của kiến trúc re-ranking trong hệ thống hai giai đoạn.

4.4.6 Tổng kết

Từ các phân tích trên, có thể rút ra ba kết luận chính:

- Cross-Attention mang lại cải thiện ổn định về thứ hạng trung bình, thể hiện qua xu hướng giảm Mean Rank ở mọi cấu hình M.
- Lợi ích rõ ràng nhất xuất hiện ở các vị trí Top-K trung gian (Top-3 và Top-5), cho thấy mô hình có khả năng điều chỉnh thứ hạng hiệu quả trong phạm vi đề xuất ngắn.
- Mức cải thiện phụ thuộc vào kích thước tập ứng viên: khi M nhỏ, hiệu quả rõ ràng hơn; khi M lớn, lợi ích có xu hướng phân tán do không gian tìm kiếm rộng hơn.

Kết quả này củng cố giả thuyết rằng cơ chế Cross-Attention chủ yếu đóng vai trò tối ưu hóa tương tác ngữ nghĩa chi tiết giữa bài báo và Aims & Scope, từ đó cải thiện chất lượng xếp hạng trong giai đoạn re-ranking, thay vì thay thế hoàn toàn vai trò của giai đoạn truy hồi ban đầu.

5 Kết luận và hướng phát triển

5.1 Kết luận

Báo cáo đã nghiên cứu bài toán gợi ý hội nghị/tạp chí khoa học (Paper Submission Recommendation) dựa trên mức độ tương thích ngữ nghĩa giữa nội dung bài báo và phạm vi nghiên cứu của địa điểm công bố.

Trên cơ sở tập dữ liệu được đề xuất trong SimCPSR [13], báo cáo tiến hành so sánh và phân tích ba nhóm phương pháp chính:

- Các phương pháp dựa trên embedding tĩnh (Approach A);
- Các mô hình ngôn ngữ ngữ cảnh dựa trên Transformer (Approach B);
- Mô hình embedding kết hợp học tương phản (Approach C);
- Phương pháp đề xuất bổ sung cơ chế Cross-Attention trong giai đoạn re-ranking (Approach D).

Kết quả thực nghiệm cho thấy Approach C đạt hiệu năng cao nhất và ổn định trong giai đoạn truy hồi ban đầu (retrieval stage), nhờ khả năng học không gian biểu diễn phân biệt thông qua contrastive learning. Phương pháp này có ưu điểm về khả năng mở rộng, cho phép xử lý không gian hội nghị lớn với chi phí tính toán hợp lý.

Trong khi đó, Approach D sử dụng Cross-Attention để khai thác tương tác token-level giữa nội dung bài báo và Aims & Scope của hội nghị. Kết quả thực nghiệm chứng minh rằng phương pháp này giúp cải thiện Mean Rank và các chỉ số Hit@K trung gian, đặc biệt khi áp dụng trong mô hình hai giai đoạn (retrieval–re-ranking).

Từ đó, có thể rút ra kết luận quan trọng:

> Approach C phù hợp cho giai đoạn truy hồi ban đầu nhờ khả năng mở rộng tốt, trong khi Approach D nên được sử dụng như một re-ranking stage nhằm tối ưu chất lượng xếp hạng cuối cùng.

Sự kết hợp giữa hai phương pháp tạo thành một kiến trúc hai giai đoạn cân bằng giữa hiệu quả tính toán và chất lượng gợi ý, phù hợp với các hệ thống gợi ý công bố khoa học trong thực tế.

5.2 Hạn chế

Mặc dù đạt được những kết quả tích cực, báo cáo vẫn tồn tại một số hạn chế:

- **Giới hạn về tài nguyên tính toán:** Các thí nghiệm re-ranking chỉ được thực hiện trên tập con dữ liệu do chi phí tính toán cao của Cross-Attention. Điều này có thể ảnh hưởng đến tính tổng quát của kết quả.
- **Không gian ứng viên phụ thuộc vào retrieval stage:** Mô hình re-ranking không thể cải thiện các trường hợp mà hội nghị đúng không xuất hiện trong Top-M ban đầu. Do đó, hiệu quả tổng thể phụ thuộc mạnh vào chất lượng của Approach C.

- **Chưa khai thác thông tin cấu trúc:** báo cáo chủ yếu dựa trên nội dung văn bản (Title, Abstract, Keywords, Aims & Scope) mà chưa khai thác các yếu tố cấu trúc khác như lĩnh vực phân loại, mạng trích dẫn hoặc lịch sử xuất bản.
- **Thiếu đánh giá thực tế người dùng:** Các độ đo sử dụng chủ yếu dựa trên ranking metrics, chưa có đánh giá định tính hoặc khảo sát người dùng thực tế.

5.3 Hướng phát triển trong tương lai

Dựa trên các kết quả và hạn chế đã phân tích, một số hướng nghiên cứu tiềm năng bao gồm:

- **Mở rộng quy mô re-ranking:** Tối ưu kiến trúc Cross-Attention hoặc áp dụng các biến thể hiệu quả hơn (ví dụ: late interaction, sparse attention) nhằm giảm chi phí tính toán và cho phép áp dụng trên tập dữ liệu lớn hơn.
- **Cải thiện retrieval stage:** Nghiên cứu các kỹ thuật contrastive learning nâng cao hoặc multi-task learning để tăng xác suất đưa hội nghị đúng vào Top-M.
- **Khai thác thông tin bổ sung:** Kết hợp thông tin mạng trích dẫn, lĩnh vực nghiên cứu, hoặc embedding từ knowledge graph nhằm tăng tính chính xác và khả năng tổng quát hóa.
- **Hệ thống gợi ý thích ứng:** Phát triển hệ thống cá nhân hóa dựa trên hồ sơ tác giả, lịch sử công bố hoặc mục tiêu chiến lược của người dùng.
- **Đánh giá thực nghiệm thực tế:** Thực hiện khảo sát người dùng hoặc triển khai thử nghiệm trong môi trường thực tế nhằm đánh giá hiệu quả ứng dụng.

Trong tương lai, việc tích hợp các hướng phát triển trên có thể giúp xây dựng một hệ thống gợi ý công bố khoa học thông minh, có khả năng mở rộng tốt và đáp ứng nhu cầu thực tiễn của cộng đồng nghiên cứu.

Tài liệu

[1] D. J. de Solla Price, *Little Science, Big Science*. Columbia University Press, 1963.

[2] Gerard Salton and Christopher Buckley. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5):513–523, 1988.

[3] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention Is All You Need. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[4] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient Estimation of Word Representations in Vector Space. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2013.

[5] Piotr Bojanowski, Edouard Grave, Armand Joulin, and Tomas Mikolov. Enriching Word Vectors with Subword Information. *Transactions of the Association for Computational Linguistics*, 5:135–146, 2017.

[6] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *Proceedings of NAACL-HLT*, 2019.

[7] Yiming Zhang, Zeyu Dai, and Yi Fang. SimCPSR: Simple Contrastive Learning for Paper Submission Recommendation. *arXiv preprint arXiv:2205.05940*, 2022.

[8] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention Is All You Need. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[9] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. Neural Machine Translation by Jointly Learning to Align and Translate. In *International Conference on Learning Representations (ICLR)*, 2015.

[10] Zhouhan Lin, Minwei Feng, Cicero Nogueira dos Santos, Mo Yu, Bing Xiang, Bowen Zhou, and Yoshua Bengio. A Structured Self-Attentive Sentence Embedding. In *International Conference on Learning Representations (ICLR)*, 2017.

[11] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. In *Proceedings of EMNLP*, 2019.

[12] Omar Khattab and Matei Zaharia. ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction over BERT. In *Proceedings of SIGIR*, 2020.

[13] Duc H. Le, Tram T. Doan, Son T. Huynh, and Binh T. Nguyen. SimCPSR: Simple Contrastive Learning for Paper Submission Recommendation System. In *Proceedings of the International Conference on ACIIDS*, 2022.

[14] Donghui Wang, Yanchun Liang, Dong Xu, Xiaoyue Feng, and Renchu Guan. A Content-Based Recommender System for Computer Science Publications. *Knowledge-Based Systems*, 157:1–9, 2018.

[15] Huynh Thanh Son, Huynh Tan Phong, and Nguyen Huu Dac. An Efficient Approach for Paper Submission Recommendation. In *Proceedings of IEEE TENCON*, pages 726–731, 2020.

[16] Dac Nguyen, Son Huynh, Phong Huynh, Cuong V. Dinh, and Binh T. Nguyen. S2CFT: A New Approach for Paper Submission Recommendation. In *SOFSEM 2021*, pages 563–573. Springer, 2021.

[17] Son T. Huynh, Nhi Dang, Phong T. Huynh, Dac H. Nguyen, and Binh T. Nguyen. A Fusion Approach for Paper Submission Recommendation System. In *Advances and Trends in Artificial Intelligence*, pages 72–83. Springer, 2021.

[18] Huma Samin and Tayyaba Azim. Knowledge-Based Recommender System for Academia Using Machine Learning. *IEEE Access*, 7:67081–67093, 2019.

[19] Xiaomci Bai, Mengyang Wang, Ivan Lee, Zhuo Yang, Xiangjie Kong, and Feng Xia. Scientific Paper Recommendation: A Survey. *IEEE Access*, 7:9324–9339, 2019.

[20] Dinh V. Cuong, Dac H. Nguyen, Son Huynh, Phong Huynh, Cathal Gurrin, Minh-Son Dao, Duc-Tien Dang-Nguyen, and Binh T. Nguyen. A Framework for Paper Submission Recommendation System. 2020.

[21] Jeffrey Pennington, Richard Socher, and Christopher D. Manning. GloVe: Global Vectors for Word Representation. In *Proceedings of EMNLP*, pages 1532–1543, 2014.

[22] Piotr Bojanowski, Edouard Grave, Armand Joulin, and Tomas Mikolov. Enriching Word Vectors with Subword Information. *Transactions of the ACL*, 5:135–146, 2017.

[23] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep Learning. *Nature*, 521:436–444, 2015.

[24] Sepp Hochreiter and Jürgen Schmidhuber. Long Short-Term Memory. *Neural Computation*, 9(8):1735–1780, 1997.

[25] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *Proceedings of NAACL*, pages 4171–4186, 2019.

[26] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. RoBERTa: A Robustly Optimized BERT Pretraining Approach. *arXiv preprint arXiv:1907.11692*, 2019.

[27] Thomas Wolf et al. Transformers: State-of-the-Art Natural Language Processing. In *Proceedings of EMNLP (System Demonstrations)*, pages 38–45, 2020.

[28] Adam Paszke et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library. In *Advances in Neural Information Processing Systems*, 2019.

[29] Amit Chaudhary. Universal Sentence Encoder Visually Explained. Blog post, 2020. URL: https://amitness.com/posts/universal-sentence-encoder.